Heckman 选择模型

样本选择偏误、两阶段估计与排他性变量

金融数据分析与建模

本章主线

- 为什么“只在可观测样本上回归”可能产生偏误
- 如何区分 selection equation 与 outcome equation
- inverse Mills ratio 修正了什么
- 如何从政策背景和样本产生机制寻找排他性变量
- 企业银行贷款利率案例：从模型设定到结果解释

从银行贷款利率样本说起

研究问题：企业特征如何影响银行贷款利率？

$$rate_i = x_i'\beta + u_i$$

问题在于，$rate_i$ 并非对所有企业都可观测：

- 企业需要先获得银行贷款
- 数据中需要披露贷款合同或利息支出信息
- 未获得贷款企业没有可观测贷款利率

一个两阶段的经济过程

银行贷款利率样本通常经历两个过程：

- **选择过程**：银行先决定是否发放贷款，企业是否进入贷款利率样本
- **结果过程**：在获得贷款企业中，银行与企业形成贷款利率

$$\text{firm characteristics} \rightarrow loan_i \rightarrow rate_i$$

若获得贷款不是随机事件，只在获得贷款企业中做 OLS，本质上是在一个经过筛选的样本中估计结果方程。

选择机制与结果观测

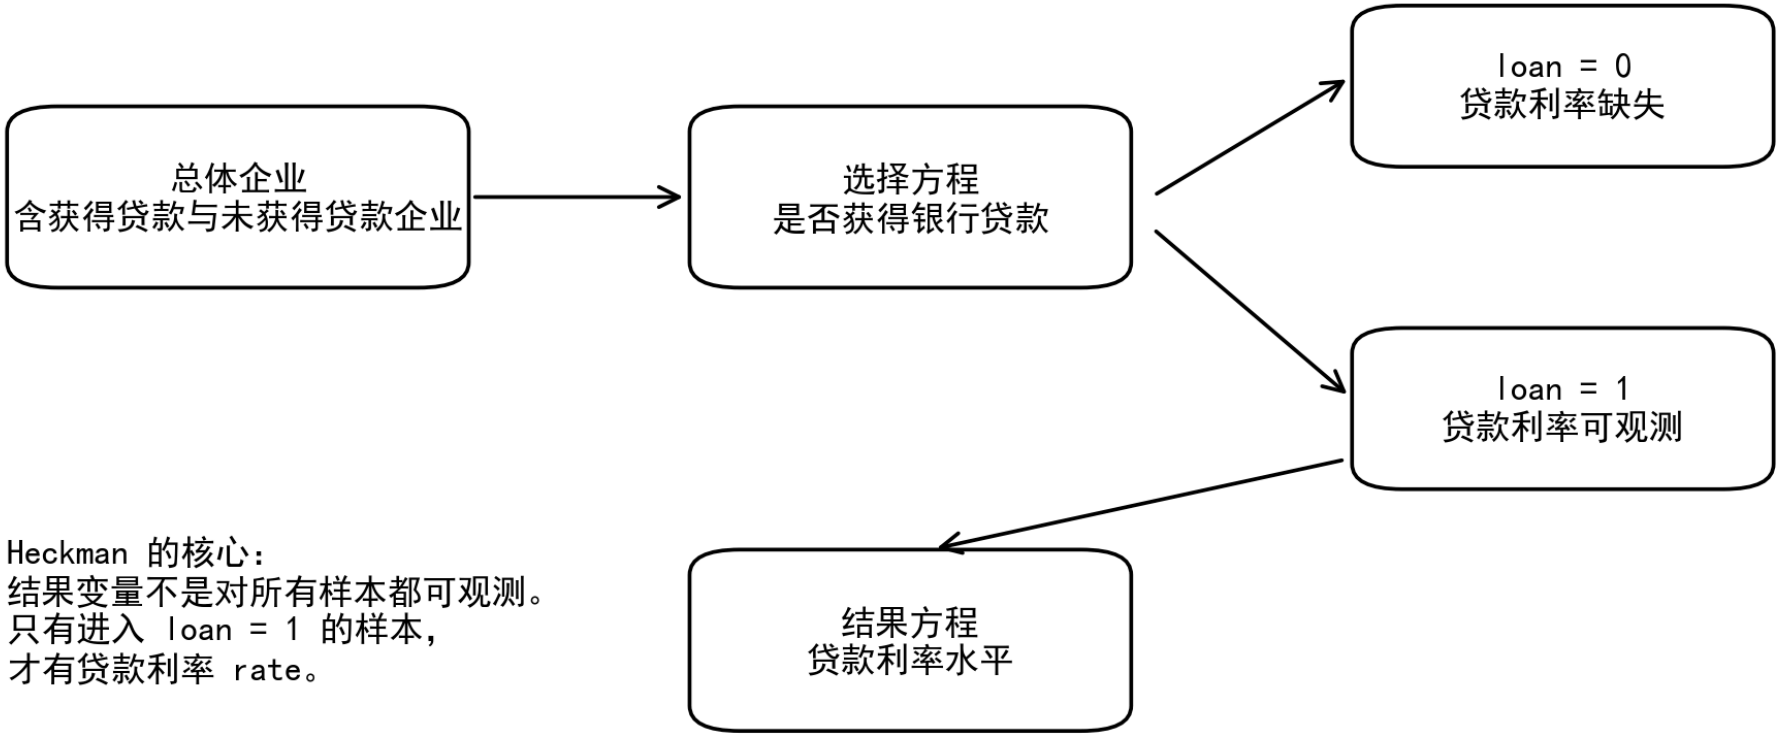

Heckman 的核心：
结果变量不是对所有样本都可观测。
只有进入 loan = 1 的样本，
才有贷款利率 rate。

Heckman 与 Tobit 的区别

> Tobit 模型中，未超过阈值的结果通常仍以边界值形式进入数据，例如 $y_i=0$。Heckman 选择模型中，未被选择样本的结果变量并不是 0，而是根本不可观测。

贷款案例中，没有获得贷款的企业不是贷款利率为 0，而是没有可观测贷款利率。

从政策背景理解 selection 方程

银行贷款不是简单的市场交易结果，而是带有信息筛选、风险评估和制度约束的审批过程。

贷款利率样本可能来自以下筛选机制：

- 企业是否提出融资申请
- 银行是否愿意进入授信审查流程
- 企业是否拥有抵押品或担保
- 所在地区是否有银行网点或政银企对接窗口
- 企业是否披露贷款合同或利息支出明细

排他性变量来自样本产生过程

本地银行网点密度、园区金融服务站、政银企对接平台、信用担保服务覆盖等变量，可能显著影响企业是否获得贷款。

若这些变量主要影响“能否获得贷款”，但在控制企业风险和财务特征后不直接决定贷款合同利率，就可以作为选择方程中的排他性变量候选。

> 排他性变量不能事后硬凑。它应来自样本选择过程本身。

从因果推断角度理解 Heckman

普通 OLS 试图识别：

$$E(y_i \mid x_i)$$

但存在样本选择时，研究者实际看到的是：

$$E(y_i \mid x_i, s_i = 1)$$

其中，$s_i = 1$ 表示结果变量被观测到。

选择导致的遗漏变量偏误

如果进入样本本身与结果方程的未观测因素相关：

$$s_i \not\perp u_i \mid x_i$$

选择变量 s_i 就携带了未观测信息。直接在 $s_i = 1$ 的样本中回归，便存在遗漏变量偏误。

> Heckman 模型可以理解为处理 selection-induced confounding 的一种参数化方法。

Heckman 模型的基本设定

潜在结果方程：

$$y_i^* = x_i'\beta + u_i$$

选择方程：

$$s_i^* = z_i'\gamma + v_i$$

实际选择结果：

$$s_i = \begin{cases} 1, & s_i^* > 0 \\ 0, & s_i^* \leq 0 \end{cases}$$

结果变量的观测规则

$$y_i = \begin{cases} y_i^*, & s_i = 1 \\ \text{missing}, & s_i = 0 \end{cases}$$

标准 Heckman 模型假设：

$$\begin{pmatrix} u_i \\ v_i \end{pmatrix} \sim N\left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_u^2 & \rho\sigma_u \\ \rho\sigma_u & 1 \end{pmatrix}\right]$$

若 $\rho \neq 0$，样本选择偏误就会出现。

贷款利率案例：结果方程

本章把贷款利率视为 outcome，把是否获得贷款视为 selection。

$$rate_i^* = \beta_0 + \beta_1 size_i + \beta_2 cash_i + \beta_3 lev_i + \beta_4 profit_i + \beta_5 collateral_i + u_i$$

结果方程解释的是：在进入贷款样本后，企业特征如何影响贷款利率。

贷款利率案例：选择方程

$$loan_i^* = \gamma_0 + \gamma_1 size_i + \gamma_2 cash_i + \gamma_3 lev_i + \gamma_4 profit_i + \gamma_5 collateral_i + \gamma_6 bankaccess_i + \gamma_7 creditwindow_i + v_i$$

- `bank_access`：本地银行服务可得性
- `credit_window`：政银企对接窗口覆盖
- 二者作为排他性变量候选

排他性变量的设定逻辑

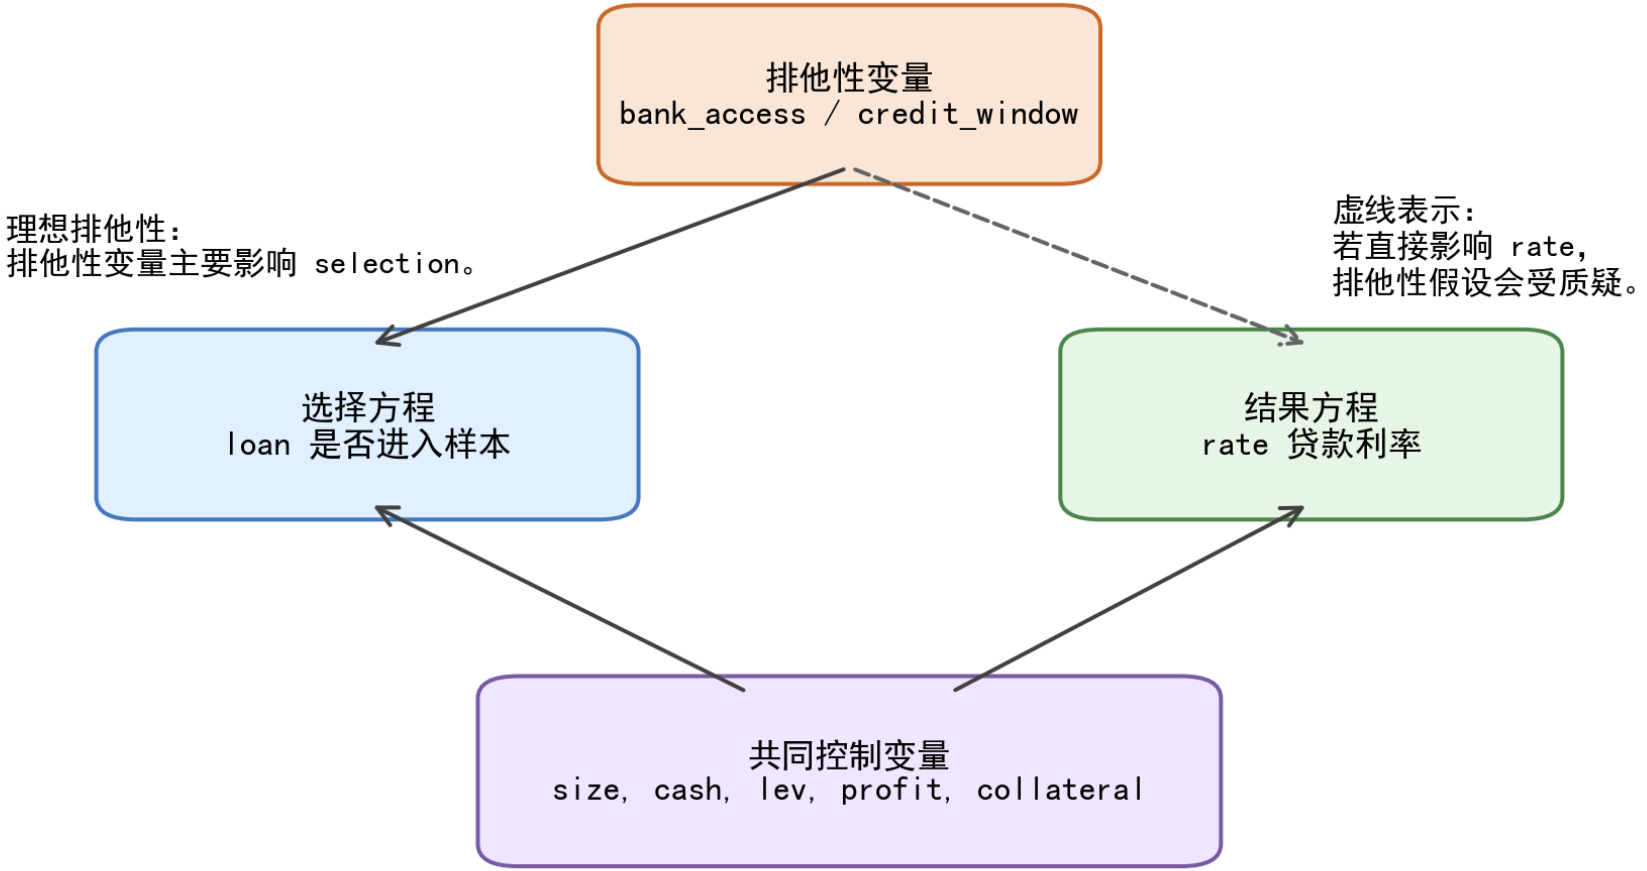

共同控制变量同时进入选择方程与结果方程。

变量进入哪个方程?

变量	含义	进入方程
`rate`	银行贷款利率	结果变量
`loan`	是否获得银行贷款	选择变量
`size`, `cash`, `lev`, `profit`	企业财务特征	两个方程
`collateral`	抵押品充足程度	两个方程
`bank_access`	本地银行服务可得性	选择方程
`credit_window`	政银企对接窗口覆盖	选择方程

经典文献的设定思路

> Heckman (1979) 将样本选择偏误表述为 specification error。关键不是“样本变少了”，而是被观测样本的误差项条件均值不再为 0。

Mroz (1987) 的劳动供给研究提供了经典应用：工资只对就业女性可观测，因此选择方程解释是否就业，结果方程解释工资水平。

被选择与未被选择样本差异

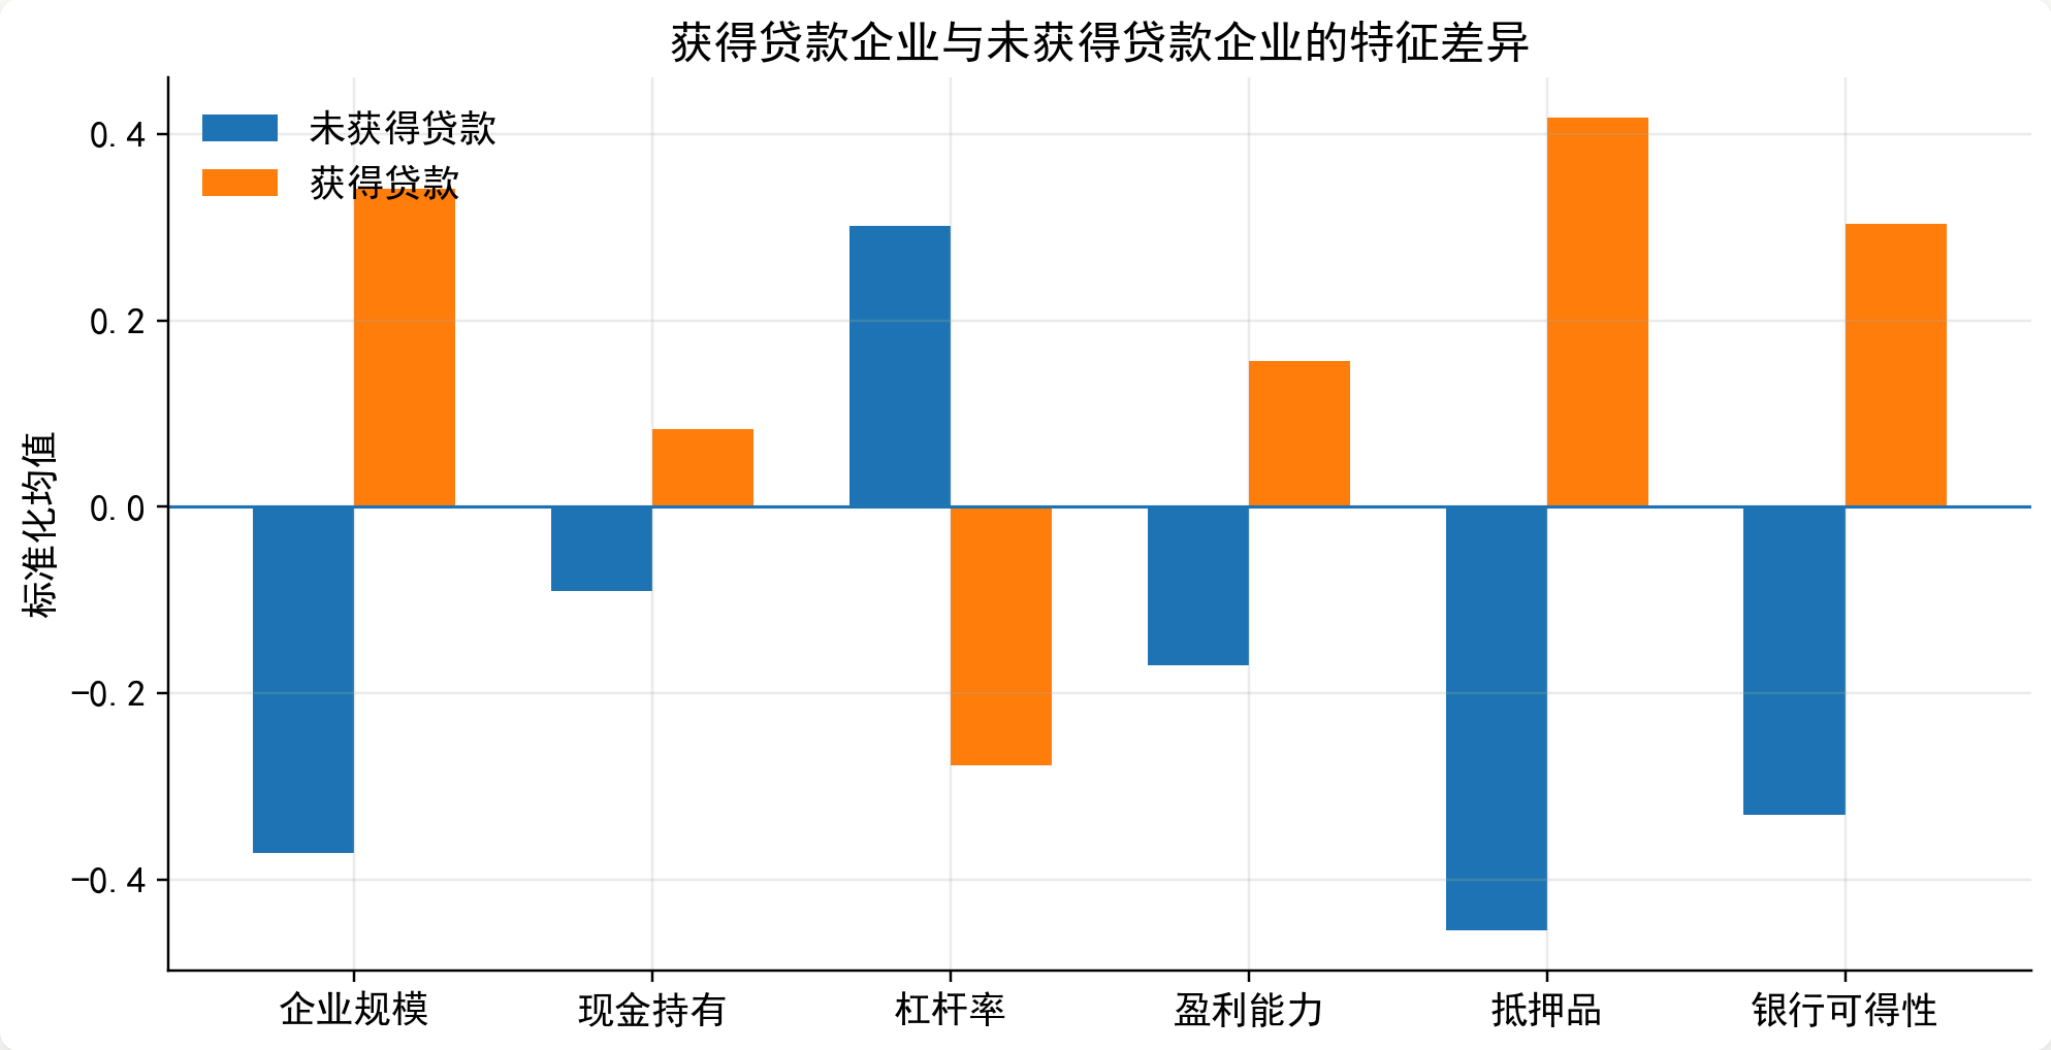

潜在贷款利率与观测贷款利率

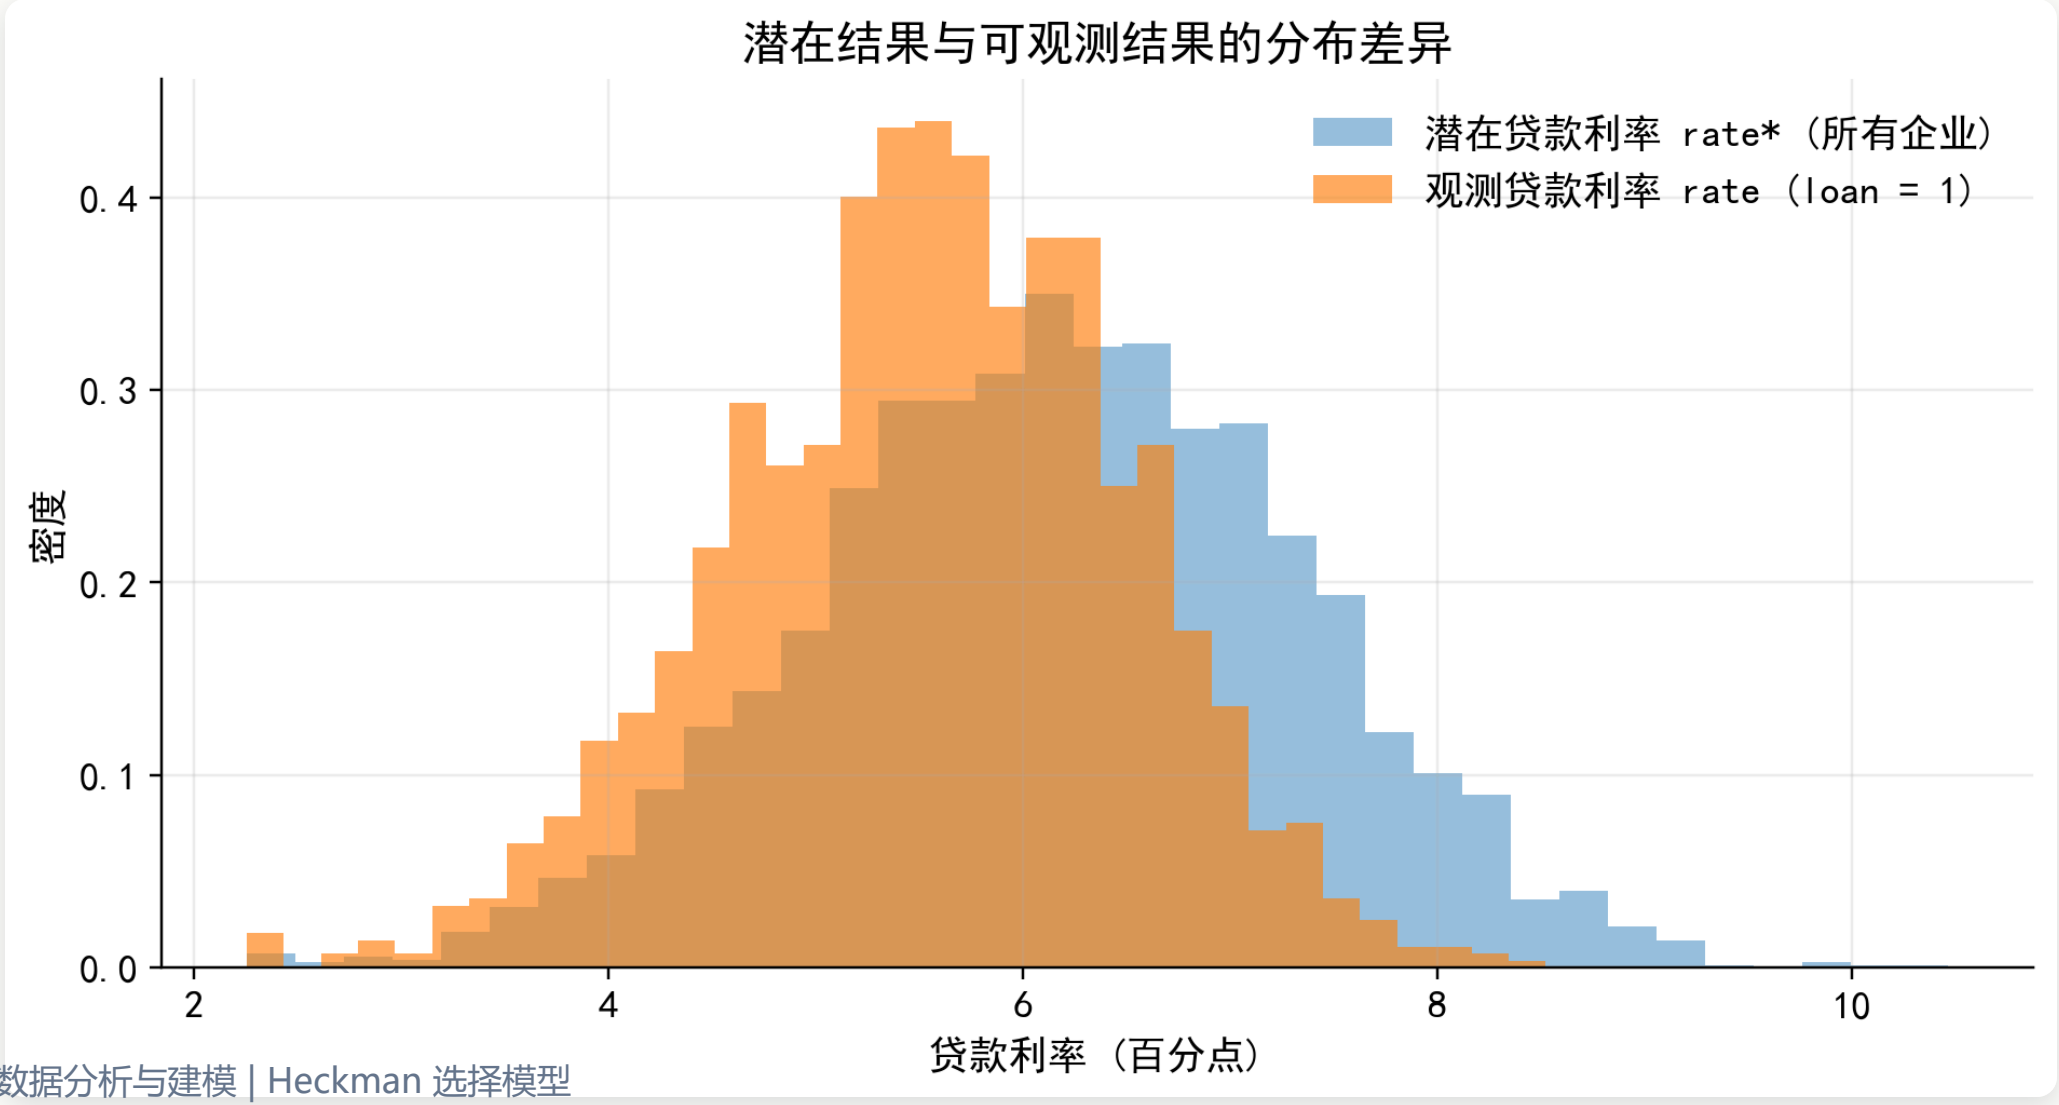

inverse Mills ratio 的来源

在获得贷款样本中观察到：

$$y_i = x_i'\beta + u_i, \quad s_i = 1$$

但 $s_i = 1$ 等价于：

$$s_i^* = z_i'\gamma + v_i > 0$$

$$v_i > -z_i'\gamma$$

因此，被选择样本中的误差项不再具有零条件均值。

IMR 修正项

在联合正态假设下：

$$E(u_i \mid v_i > -z_i'\gamma) = \rho\sigma_u\lambda(z_i'\gamma)$$

$$\lambda(z_i'\gamma) = \frac{\phi(z_i'\gamma)}{\Phi(z_i'\gamma)}$$

于是：

$$E(y_i \mid x_i, z_i, s_i = 1) = x_i'\beta + \rho\sigma_u\lambda(z_i'\gamma)$$

第二阶段回归

令 $\theta = \rho\sigma_u$，第二阶段可写为：

$$y_i = x_i'\beta + \theta\lambda_i + \varepsilon_i, \quad s_i = 1$$

λ_i 就是 inverse Mills ratio。

> IMR 不是普通控制变量，而是由选择方程推导出来的选择修正项。其含义是：在给定可观测变量后，一个观测值进入可观测样本的非随机程度。

IMR 的解释边界

> IMR 显著通常说明选择过程与结果方程误差项存在相关性，但它不能自动证明排他性变量有效。

排他性变量是否合理，仍取决于：

- 制度背景
- 经济机制
- 变量定义
- 控制变量设定
- 稳健性分析

Heckman 两步法

1. **第一步**：估计选择方程 Probit

$$P(s_i = 1 \mid z_i) = \Phi(z_i'\gamma)$$

2. **计算 IMR**：

$$\hat{\lambda}_i = \frac{\phi(z_i'\hat{\gamma})}{\Phi(z_i'\hat{\gamma})}$$

3. **第二步**：在 $s_i = 1$ 样本中，把 $\hat{\lambda}_i$ 加入结果方程。

Python 手动两步法

```python
# 第一阶段：Probit 选择方程
Z = sm.add_constant(df[[
    "size", "cash", "lev", "profit", "collateral",
    "bank_access", "credit_window"
]])
probit_res = sm.Probit(df["loan"], Z).fit()

# 计算 inverse Mills ratio
xb = probit_res.predict(linear=True)
df["imr"] = norm.pdf(xb) / norm.cdf(xb)

# 第二阶段：仅在被选择样本中估计结果方程
df_s = df.loc[df["loan"] == 1].copy()
X = sm.add_constant(df_s[[
    "size", "cash", "lev", "profit", "collateral", "imr"
]])
ols_res = sm.OLS(df_s["rate"], X).fit(cov_type="HC1")
```

IMR 与估计结果可视化

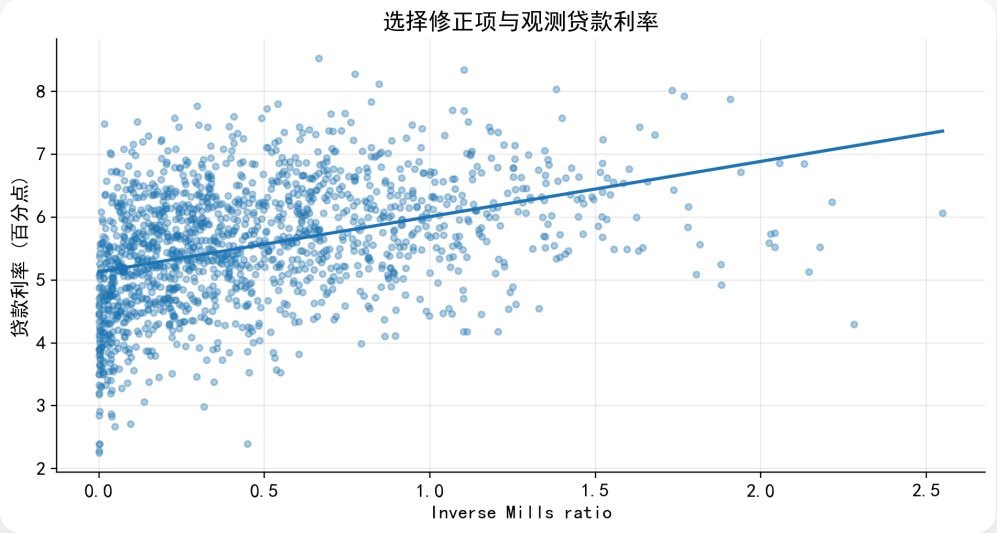

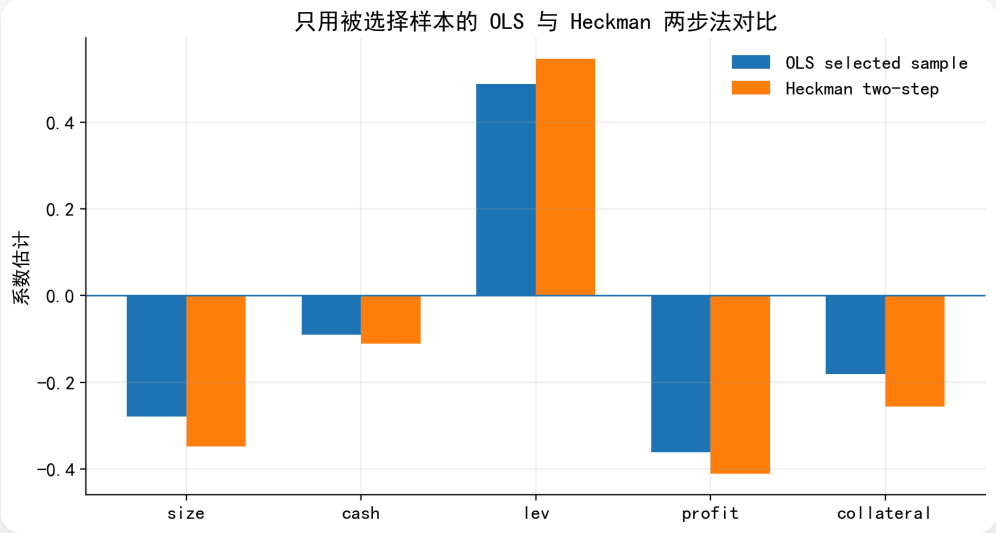

Stata：读取数据与基准 OLS

```
* 读取模拟数据
clear all
set more off
import delimited "./data/heckman_loan_sim.csv", clear

* 基准 OLS：只在获得贷款企业中估计贷款利率
reg rate size cash lev profit collateral if loan == 1, ///
    vce(robust)
estimates store OLS_selected
```

Stata：手动两步法

```
* 第一阶段 Probit
probit loan size cash lev profit collateral ///
    bank_access credit_window
predict xb_select, xb

* 计算 inverse Mills ratio
gen imr_manual = normalden(xb_select) / normal(xb_select)

* 第二阶段加入 IMR
reg rate size cash lev profit collateral imr_manual ///
    if loan == 1, vce(robust)
estimates store Manual_2step
```

Stata：官方 Heckman 估计

```
* Heckman 两阶段估计
heckman rate size cash lev profit collateral, ///
    select(loan = size cash lev profit collateral ///
        bank_access credit_window) ///
    twostep first mills(imr_official)
estimates store Heckman_2step

* Heckman 极大似然估计
heckman rate size cash lev profit collateral, ///
    select(loan = size cash lev profit collateral ///
        bank_access credit_window) ///
    mle first vce(robust)
estimates store Heckman_ML
```

Python 中的直接估计路径

Python 中可以估计 Heckman / Heckit 模型，但生态不如 Stata 的 `heckman` 稳定统一。

可按以下顺序选择工具：

- 课堂演示：`statsmodels` 的 Probit + OLS 手动两步法
- 专门实现：尝试 `py4etrics` 的 Heckit 功能
- 论文核对：使用 Stata `heckman` 复核
- 复杂结构：考虑 Stata 扩展命令或贝叶斯建模

提示词：生成 Heckman 估计代码

> 我正在分析一个 Heckman 选择模型。结果变量是 `结果变量名`，只有在 `选择变量名=1` 时才可观测。结果方程解释变量包括 `结果方程变量列表`，选择方程解释变量包括 `选择方程变量列表`，其中 `排他性变量名` 只进入选择方程。请帮我生成 Python 代码，完成 Probit 第一阶段、inverse Mills ratio 计算、第二阶段 OLS 回归、结果表整理和基本解释。代码需要包含中文注释。

提示词：检查排他性变量

我正在为 Heckman 选择模型设计排他性变量。研究问题是 `研究问题`，结果变量是 `结果变量`，选择变量是 `选择变量`，候选排他性变量是 `变量名`。请从经济机制、制度背景、可能的直接效应、需要加入的控制变量和稳健性检验五个角度，评估这个变量是否适合作为选择方程中的排他性变量。

Stata 扩展命令

场景	Stata 命令	说明
连续结果变量存在样本选择	`heckman`	标准 Heckman selection model
二元结果变量存在样本选择	`heckprobit`	outcome 为 Probit
有序结果变量存在样本选择	`heckoprobit`	outcome 为 ordered probit
计数结果变量存在样本选择	`heckpoisson`	outcome 为 Poisson
内生切换回归	`movestay`	不同 regime 下结果方程不同
多方程混合模型	`cmp`	用户扩展命令

实证解释的写作顺序

- 第一阶段 Probit：哪些因素影响企业进入贷款利率样本
- 排他性变量：是否显著影响贷款可得性
- 第二阶段结果方程：企业特征如何影响贷款利率
- IMR 系数：选择修正项是否重要
- OLS 与 Heckman 对比：选择修正是否改变核心结论

> 第一阶段不是附属回归，而是在刻画样本如何产生。

与其他受限因变量模型的区别

模型	观测机制	典型问题	关键设定
Tobit	潜在结果被删失，边界值仍可观测	研发投入大量为 0	一个潜在结果方程
Truncated regression	某些样本根本不进入数据	只观察高收入样本	截断后的结果方程
Two-part model	是否参与和正值强度分开	是否捐赠与捐赠金额	参与方程 + 正值方程
Heckman selection	结果变量只在被选择样本中可观测	只有获得贷款企业有贷款利率	选择方程 + 结果方程

Heckman 不是 Tobit 的替代品

> 如果未选择样本的结果变量被记录为 0，问题可能更接近 Tobit 或 Two-part model；如果未选择样本的结果变量根本不可观测，问题才更接近 Heckman selection model。

关键不是数据中有没有 0，而是结果变量的观测机制。

本章小结

- Heckman 模型处理的是结果变量只在被选择样本中可观测的问题
- selection 方程应来自样本产生机制，而不是机械加变量
- outcome 方程解释的是进入样本后的结果形成机制
- IMR 将选择过程中的非随机成分带入结果方程
- 排他性变量的合理性决定模型说服力

参考文献

- Heckman, J. J. (1979). Sample selection bias as a specification error. *Econometrica*, 47(1), 153–161. DOI: 10.2307/1912352.
- Mroz, T. A. (1987). The sensitivity of an empirical model of married women’s hours of work to economic and statistical assumptions. *Econometrica*, 55(4), 765–799. DOI: 10.2307/1911029.
- Stiglitz, J. E., & Weiss, A. (1981). Credit rationing in markets with imperfect information. *American Economic Review*, 71(3), 393–410.
- Petersen, M. A., & Rajan, R. G. (1994). The benefits of lending relationships. *Journal of Finance*, 49(1), 3–37. DOI: 10.1111/j.1540-6261.1994.tb04418.x.