Tobit 模型

受限因变量、潜变量与边际效应

金融数据分析与建模

本章主线

- 为什么大量 0 或边界值会让 OLS 出问题
- 如何从潜变量角度理解 Tobit 的 DGP
- Tobit 如何同时利用“是否被删失”和“正值大小”两类信息
- Tobit 系数与边际效应如何解释
- 企业研发投入强度案例：从模型设定到结果解释

金融数据中的受限结果变量

在企业和金融数据中，很多变量存在明显边界：

- 企业研发投入强度
- 环保投资、慈善捐赠、政府补贴
- 家庭股票投资额
- 贷款金额、保险赔付、交易金额

> 关键不在于变量是否有很多 0，而在于这些 0 的经济含义是什么。

OLS 的直觉问题

设潜在变量模型为：

$$y_i^* = x_i'\beta + u_i, \quad u_i \sim N(0, \sigma^2)$$

实际观测到的是：

$$y_i = \max(0, y_i^*)$$

`max()` 的分段写法

为便于理解，$y_i = \max(0, y_i^*)$ 也可以写成：

$$y_i = \begin{cases} 0, & y_i^* \leq 0 \\ y_i^*, & y_i^* > 0 \end{cases}$$

- 当 $y_i^* \leq 0$ 时，只能观察到 $y_i = 0$
- 当 $y_i^* > 0$ 时，才能观察到完整的连续取值
- $y_i = 0$ 不是普通的连续观测值

潜变量与观测变量

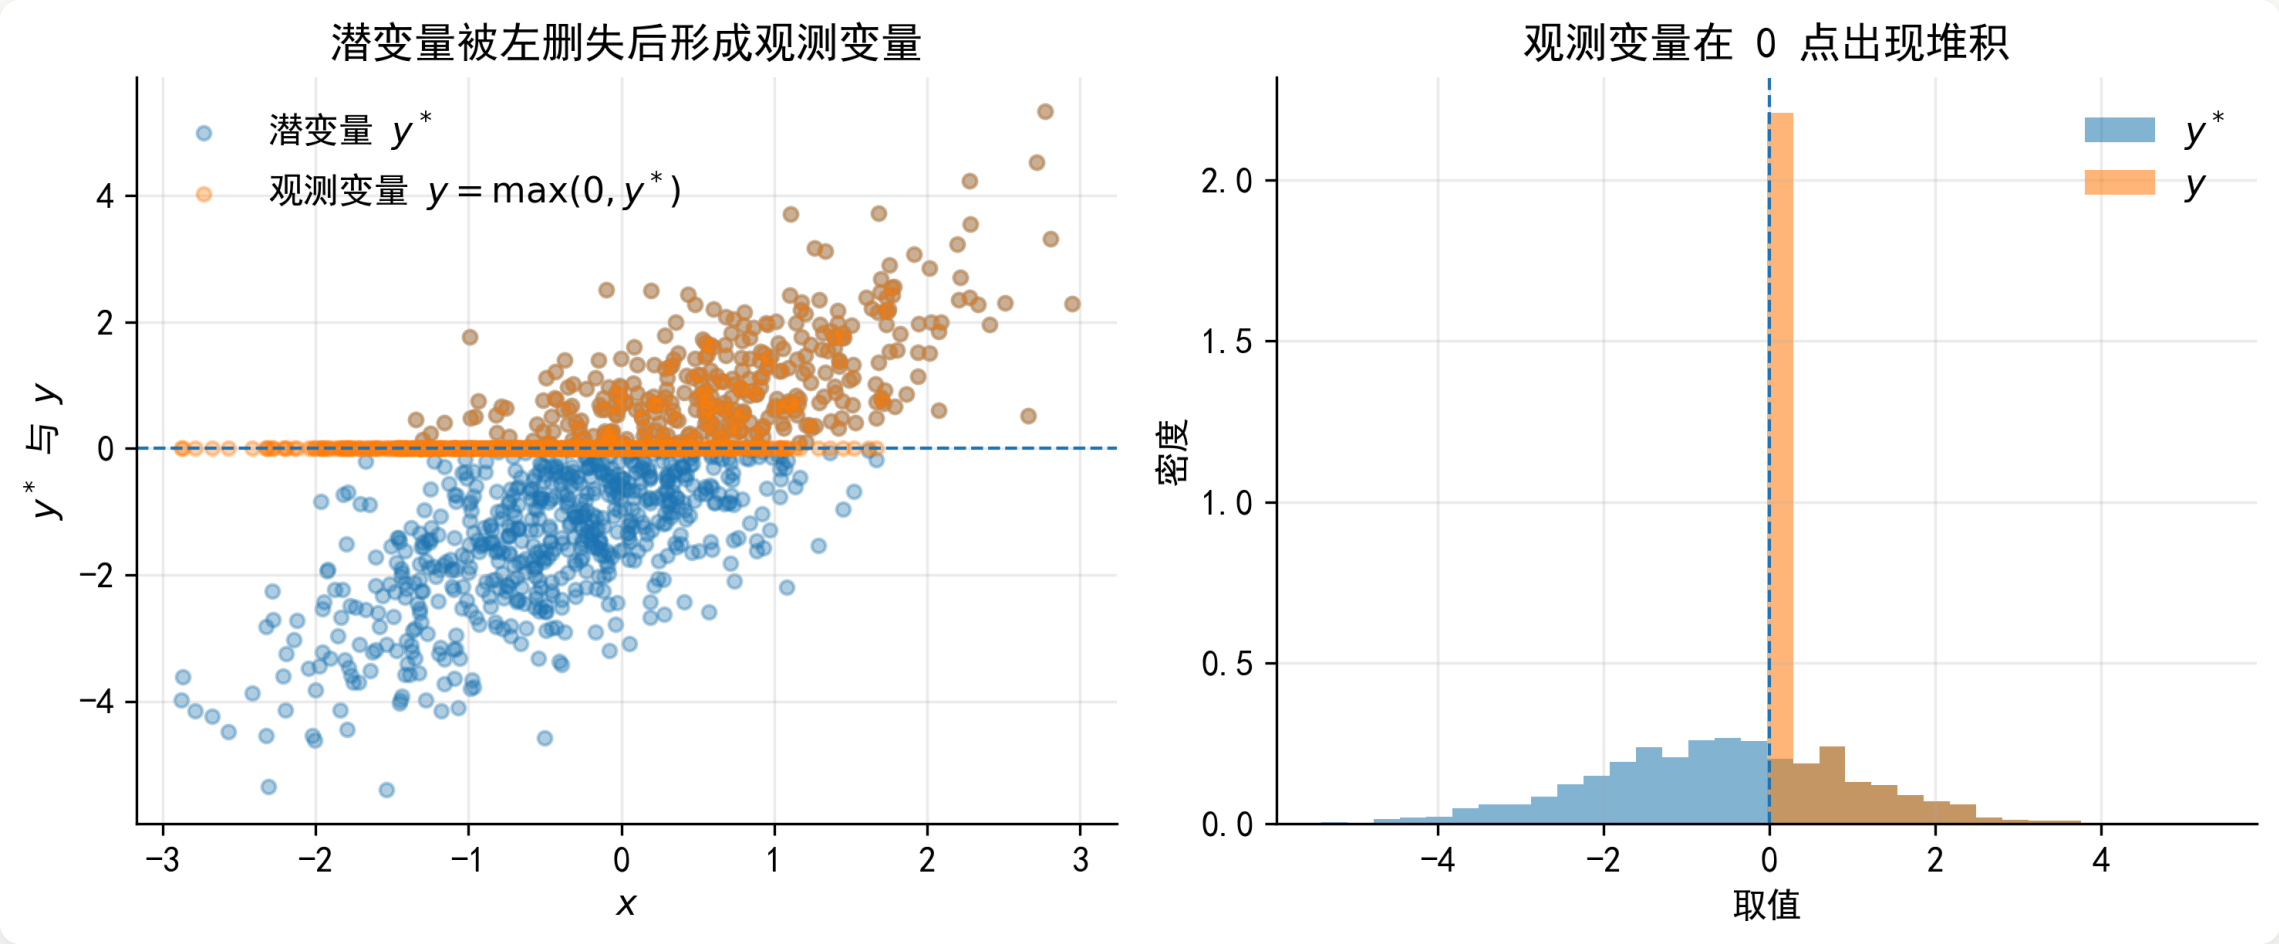

从潜在净收益理解 Tobit

以企业研发投入为例，企业是否投入研发取决于潜在净收益：

$$NetU_i = MR_i - MC_i$$

$$rd_i^* = NetU_i = x_i'\beta + u_i$$

- MR_i：研发投入的预期边际收益
- MC_i：研发投入的边际成本
- rd_i^*：潜在研发投入净收益或潜在投入强度

Tobit 的 DGP

$$rd_i = \begin{cases} 0, & rd_i^* \leq 0 \\ rd_i^*, & rd_i^* > 0 \end{cases}$$

可以概括为：

$$x_i \to rd_i^* \to rd_i$$

解释变量先影响潜在变量 rd_i^*，删失机制再把 rd_i^* 转化为观测变量 rd_i。

概念辨析：Tobit 不是“有 0 就用”

> Tobit 适合的情形是：存在一个潜在连续变量 y_i^*，但由于下限或上限约束，只能观察到被删失后的 y_i。

如果 $y_i = 0$ 本身是企业主动选择的结果，而不是潜在变量被压到边界后的观测值，Two-part model 或 Hurdle model 往往更自然。

标准左删失 Tobit

$$y_i^* = x_i'\beta + u_i, \quad u_i \mid x_i \sim N(0, \sigma^2)$$

$$y_i = \begin{cases} 0, & y_i^* \le 0 \\ y_i^*, & y_i^* > 0 \end{cases}$$

Tobit 不是把 $y_i = 0$ 的样本删掉，而是把它们作为“被删失样本”纳入似然函数。

删失、截断、样本选择

情形	样本是否在数据中	结果变量是否可观测	典型模型
删失	是	被压到边界	Tobit
截断	否	不进入样本	Truncated regression
样本选择	是或否	只在选择后观测	Heckman selection

> 判断模型前，应先判断数据生成机制，而不是只看因变量是否有 0。

似然函数的直觉

Tobit 同时利用两类信息：

- $y_i = 0$：说明 $y_i^* \leq 0$
- $y_i > 0$：既知道未被删失，也知道连续取值大小

因此，样本的似然贡献分为两部分：

$$P(y_i = 0 \mid x_i), \quad f(y_i \mid x_i, y_i > 0)$$

被删失样本的概率贡献

当 $y_i = 0$ 时:

$$
\begin{aligned}
P(y_i = 0 \mid x_i) &= P(y_i^* \leq 0 \mid x_i) \\
&= P(x_i'\beta + u_i \leq 0 \mid x_i) = P(u_i \leq -x_i'\beta \mid x_i) \\
&= \Phi\left(-\frac{x_i'\beta}{\sigma}\right)
\end{aligned}
$$

这里 $\Phi(\cdot)$ 是标准正态分布函数。

未删失样本的密度贡献

当 $y_i > 0$ 时，观察到 $y_i = y_i^*$。由于：

$$y_i^* \mid x_i \sim N(x_i'\beta, \sigma^2)$$

所以：

$$f(y_i \mid x_i) = \frac{1}{\sigma}\phi\left(\frac{y_i - x_i'\beta}{\sigma}\right)$$

Tobit 的对数似然

$$\ell(\beta,\sigma)=\sum_{y_i=0}\log\Phi\left(-\frac{x_i'\beta}{\sigma}\right)+\sum_{y_i>0}\left[-\log\sigma+\log\phi\left(\frac{y_i-x_i'\beta}{\sigma}\right)\right]$$

第一部分来自“被删失概率”，第二部分来自“未删失样本的连续密度”。

Python 中的直接估计路径

路径	定位	使用建议
`py4etrics`	Tobit / Truncated / Heckit	公式接口，适合应用
`tobit-reg`	Type I Tobit	可作为备选
`PyMC`	贝叶斯删失模型	复杂设定
自定义 MLE	可控、透明	适合教学和核对

> Python 中没有像 Stata `tobit` 那样统一、稳定、广泛使用的官方主命令。

Python 示例：估计接口思路

```python
# 如果安装了 py4etrics，可尝试公式接口
# pip install py4etrics

from py4etrics.tobit import Tobit

model = Tobit.from_formula(
    "rd ~ size + cash + lev + growth + profit",
    data=df,
    left=0
)
res = model.fit()
print(res.summary())
```

若本地包不可用，可以使用讲义中封装的 `fit_tobit()` 作为兜底方案。

Stata 示例：基础 Tobit

```
* 左删失 Tobit，删失点为 0
tobit rd size cash lev growth profit, ll(0) vce(robust)

* 平均边际效应：对观测结果 E(y|x) 的影响
margins, dydx(*) predict(ystar(0,.))

* 未删失概率的边际效应
margins, dydx(*) predict(pr(0,.))
```

Stata 的 `tobit` 命令仍然是估计和核对 Tobit 结果的稳健选择。

Tobit 系数首先解释潜在变量

Tobit 回归表中的 β_j 对应的是：

$$\frac{\partial E(y_i^* \mid x_i)}{\partial x_{ij}} = \beta_j$$

它解释的是 x_{ij} 对潜在变量 y_i^* 的影响，而不是直接对观测变量 y_i 的影响。

边际效应一：对潜在变量的影响

$$ME_j^{latent} = \frac{\partial E(y_i^* \mid x_i)}{\partial x_{ij}} = \beta_j$$

适合回答的问题：

- 企业规模是否提高潜在研发投入动机
- 现金持有是否提高企业潜在投入能力
- 某个变量是否改变企业“想投入”的程度

边际效应二：对观测变量的影响

观测变量的条件期望为：

$$E(y_i \mid x_i) = \Phi(z_i)x_i'\beta + \sigma\phi(z_i), \quad z_i = \frac{x_i'\beta}{\sigma}$$

对应边际效应：

$$ME_j^{observed} = \frac{\partial E(y_i \mid x_i)}{\partial x_{ij}} = \Phi(z_i)\beta_j$$

观测变量边际效应的含义

$ME_j^{observed}$ 同时包含两部分影响：

- 让企业从 $y_i = 0$ 变成 $y_i > 0$ 的概率变化
- 对已经越过边界的样本，其正值大小的变化

> 如果论文关心“实际观测到的因变量平均变化”，通常应重点报告这一类平均边际效应。

边际效应三：对未删失概率的影响

未删失概率为：

$$P(y_i > 0 \mid x_i) = \Phi(z_i)$$

对应边际效应：

$$ME_j^{prob} = \frac{\partial P(y_i > 0 \mid x_i)}{\partial x_{ij}} = \phi(z_i)\frac{\beta_j}{\sigma}$$

适合解释“是否跨过边界”。

正值样本条件期望

还可以关注：

$$E(y_i \mid y_i > 0, x_i) = x_i'\beta + \sigma\lambda(z_i)$$

$$\lambda(z_i) = \frac{\phi(z_i)}{\Phi(z_i)}$$

它回答的是：在已经越过边界的样本中，正值结果的条件均值如何变化。

实证中重点报告什么

研究问题	建议报告
潜在机制或理论变量	β_j
实际观测结果的平均影响	$ME_j^{observed}$
是否超过边界	ME_j^{prob}
正值样本内部强度	$E(y_i \mid y_i > 0, x_i)$ 的边际效应

> 不要只报告 Tobit 系数后，直接解释为对观测变量的影响。

Tobit、OLS 与 Probit

模型	如何处理 $y_i = 0$	适合回答的问题
OLS	当作普通连续值	平均线性关系
Probit	归并为 0/1 类别	是否为正
Tobit	潜变量被删失后的观测	是否为正 + 正值大小

如果只关心 $P(y_i > 0 \mid x_i)$，Probit 可能已经足够；如果还关心正值部分大小，才需要 Tobit 或 Two-part model。

何时适合 Tobit

- 存在潜在连续变量 y_i^*
- 因变量在下限或上限处被删失
- 同一套变量同时影响“是否超过删失点”和“超过后的取值大小”
- 正值部分基本符合正态误差和同方差假设
- 研究者关心潜在过程与观测结果之间的关系

何时不宜直接用 Tobit

- 0 值是企业主动选择，而不是删失
- 参与决策和投入强度由不同机制决定
- 正值部分高度偏态
- 因变量是计数变量
- 数据中存在大量结构性 0
- 异方差严重
- 样本进入数据本身存在选择偏误

Tobit 的替代模型

研究问题	更合适的模型
是否参与和参与强度是两个过程	Two-part model
先跨过门槛，再决定正值大小	Hurdle model
因变量是比例，位于 $[0, 1]$	Fractional response model
因变量是计数	Poisson / PPML
样本进入数据存在选择	Heckman selection
样本被截断而不是删失	Truncated regression

案例：企业研发投入强度

研究问题：企业规模、现金持有、负债率、成长性和盈利能力如何影响研发投入强度?

$$rd_i^* = \beta_0 + \beta_1 size_i + \beta_2 cash_i + \beta_3 lev_i + \beta_4 growth_i + \beta_5 profit_i + u_i$$

$$rd_i = \max(0, rd_i^*)$$

研发投入强度分布

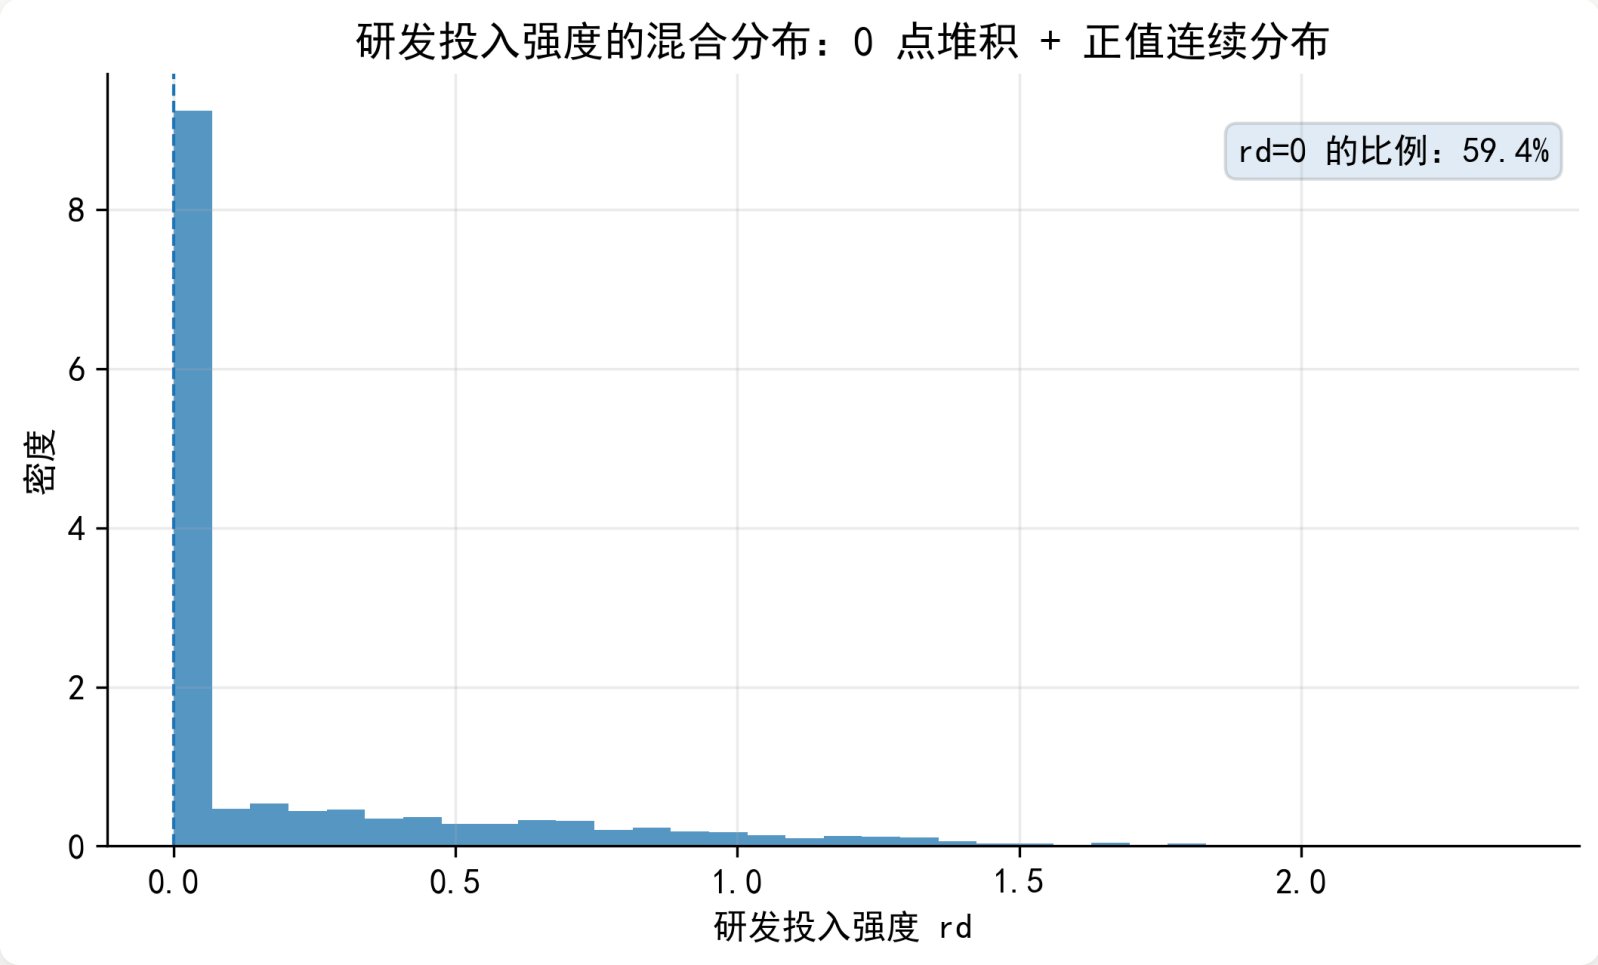
研发投入强度的混合分布：0 点堆积 + 正值连续分布
rd=0 的比例：59.4%
密度
0
2
4
6
8
0.0
0.5
1.0
1.5
2.0
研发投入强度 rd

删失点附近的数据特征

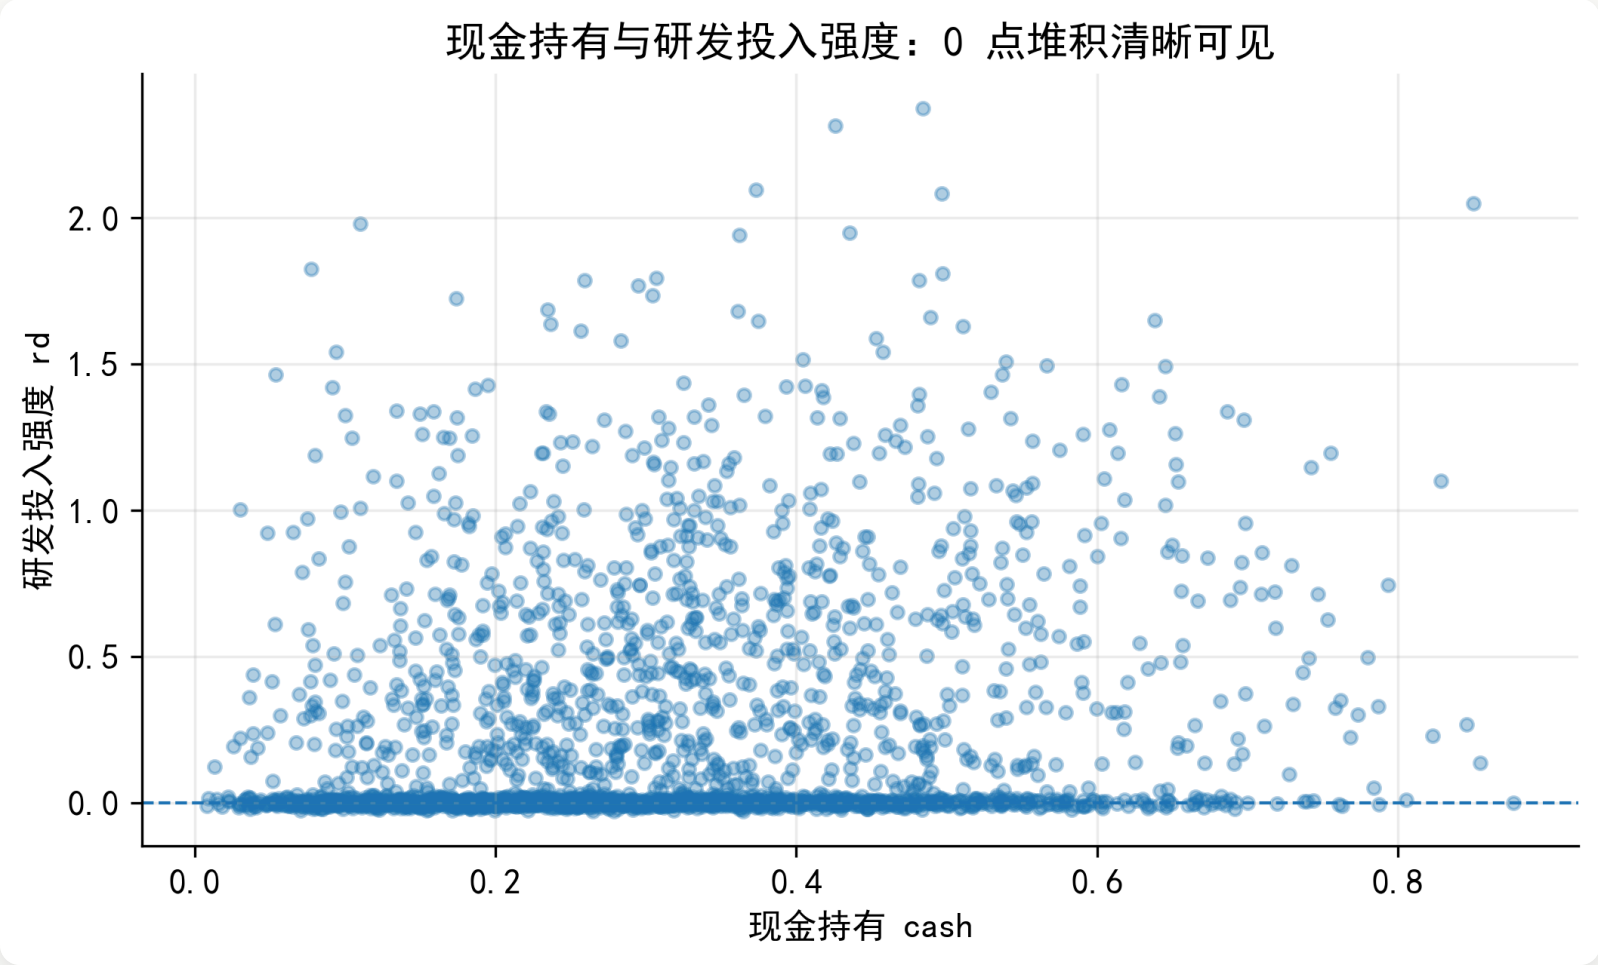
现金持有与研发投入强度：0 点堆积清晰可见
研发投入强度 rd
2.0
1.5
1.0
0.5
0.0
0.0
0.2
0.4
0.6
0.8
现金持有 cash

潜在研发强度与观测研发强度

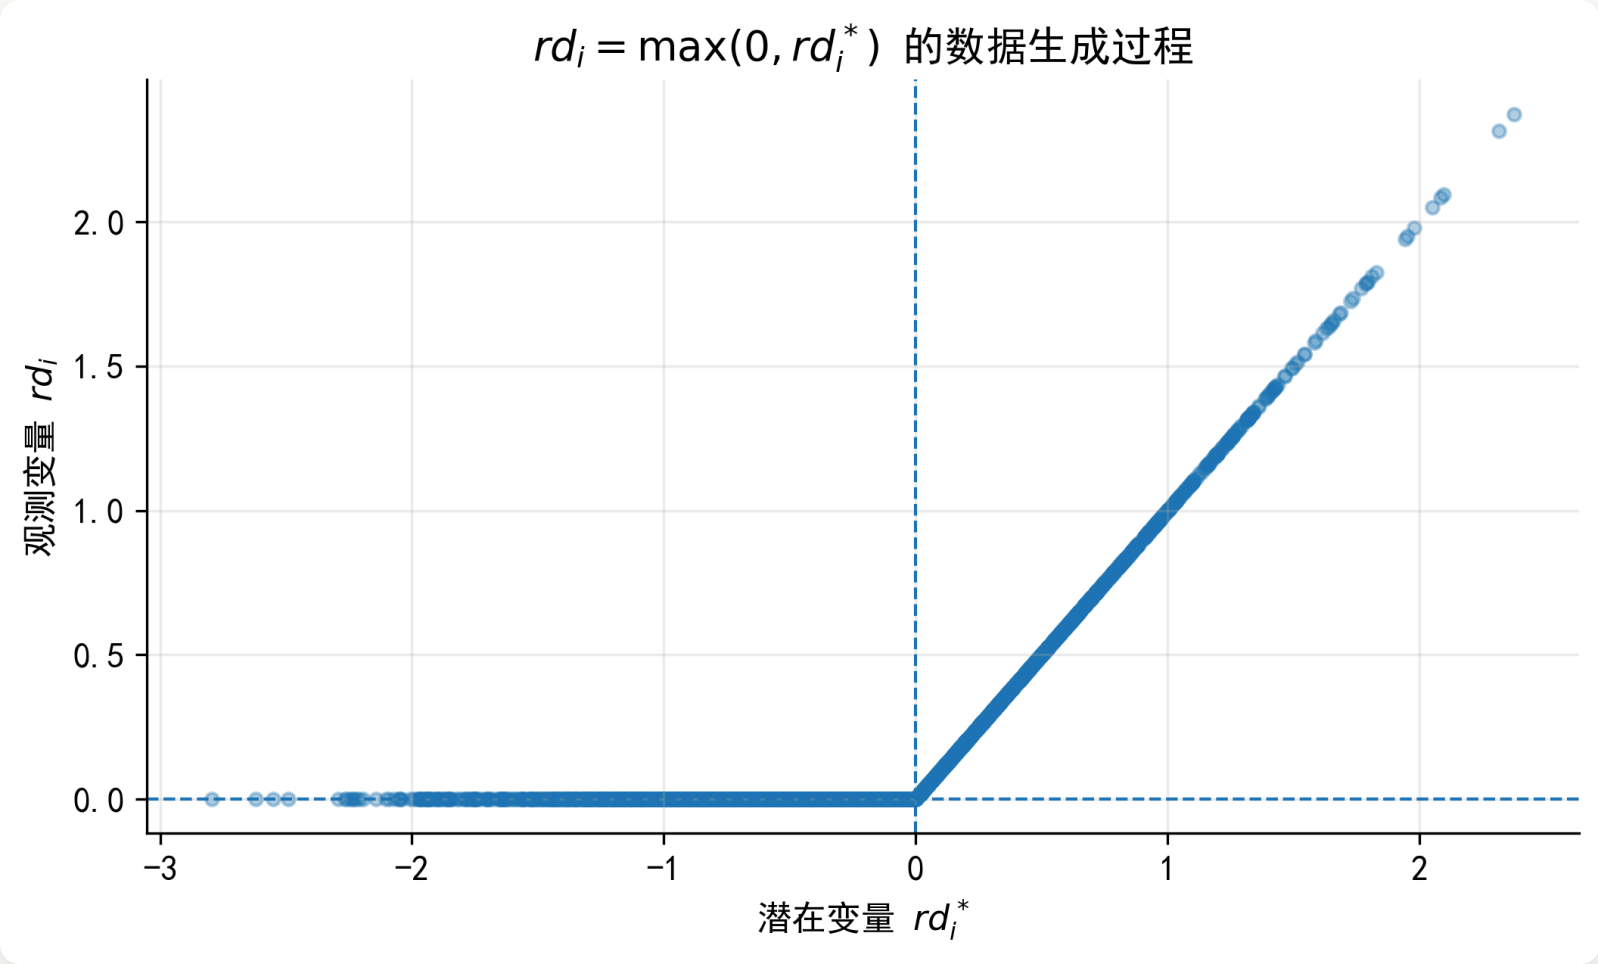

案例中的模型比较

建议依次估计：

- OLS：忽略删失机制的基准模型
- Tobit (1)：只包含核心变量
- Tobit (2)：加入财务控制变量
- Tobit (3)：加入更完整的控制变量

> OLS 在这里不是最终模型，而是用于说明忽略删失机制会如何影响结果解释。

Python 输出回归表的思路

```python
# OLS 与 Tobit 结果可能来自不同对象
# 用 pandas 统一整理更稳妥

result_table = pd.DataFrame({
    "OLS": ols_coef,
    "Tobit (1)": tobit1_coef,
    "Tobit (2)": tobit2_coef,
    "Tobit (3)": tobit3_coef,
})

result_table.round(3)
```

若只处理标准模型，可考虑 `summary_col`、`pystout` 或 `pyfixest.etable()`。

Stata 输出回归表

```
* OLS 基准模型
reg rd size cash lev growth profit, vce(robust)
estimates store OLS

* Tobit 模型
tobit rd size cash lev growth profit, ll(0) vce(robust)
estimates store Tobit

* 输出回归表
esttab OLS Tobit, ///
    b(%9.3f) se(%9.3f) ///
    star(* 0.10 ** 0.05 *** 0.01) ///
    stats(N, labels("Observations")) ///
    compress
```

现金持有与未删失概率

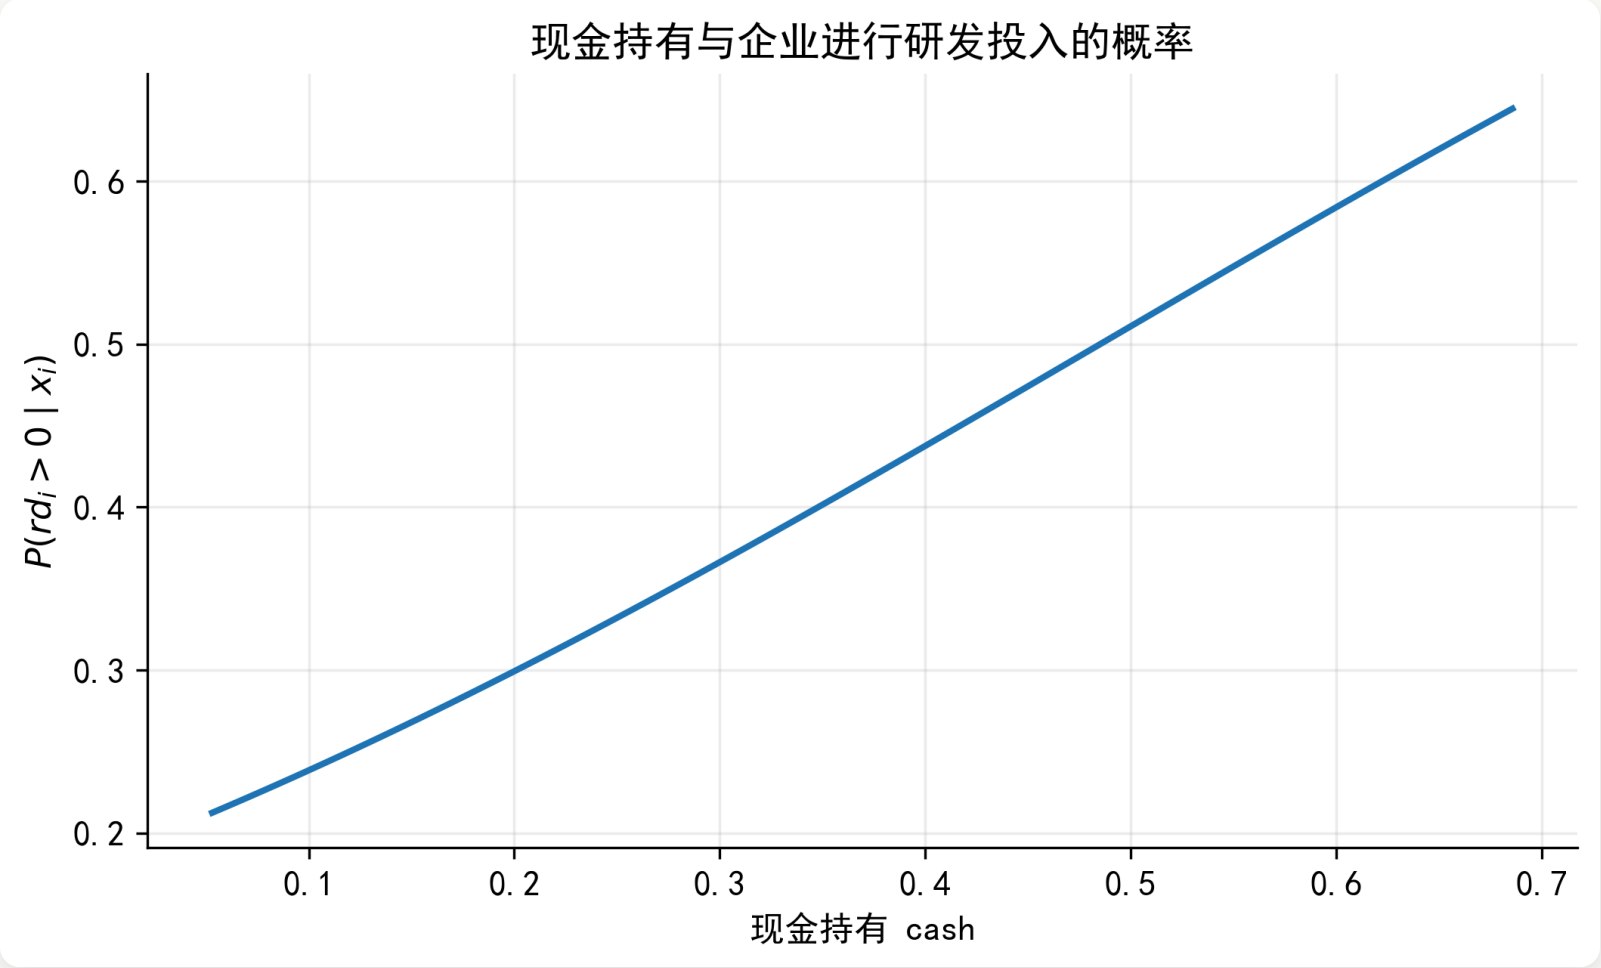
现金持有与企业进行研发投入的概率
0.6
0.5
0.4
0.3
0.2
$P(rd_i > 0 \mid x_i)$
0.1
0.2
0.3
0.4
0.5
0.6
0.7
现金持有 cash

现金持有与期望研发投入强度

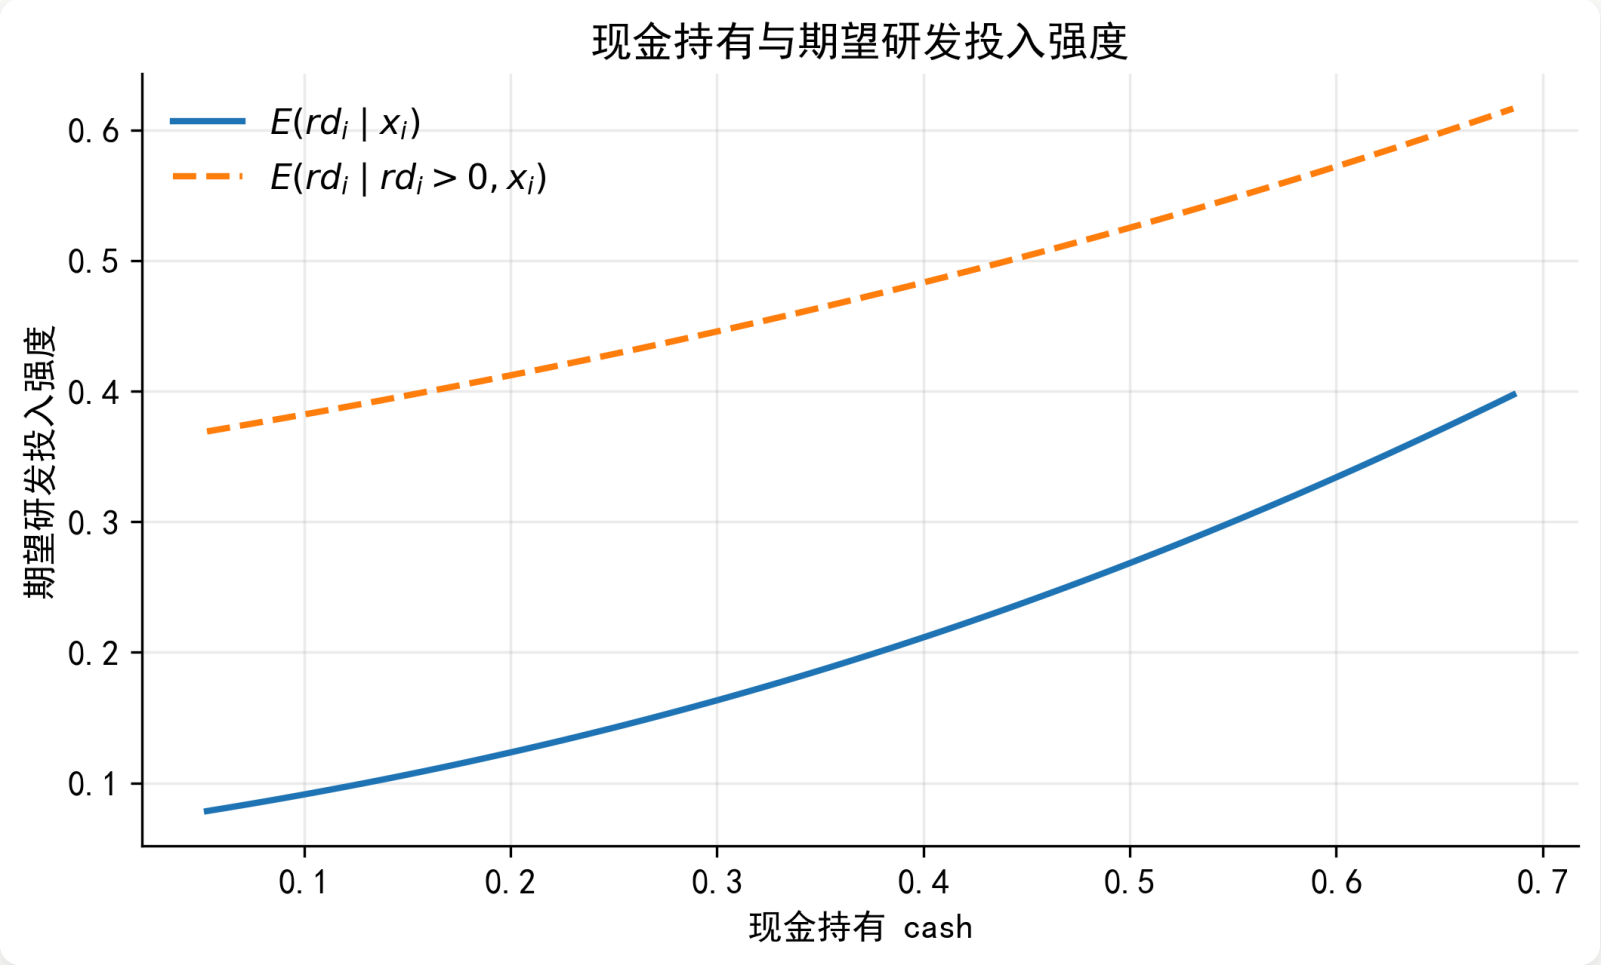

平均边际效应对比

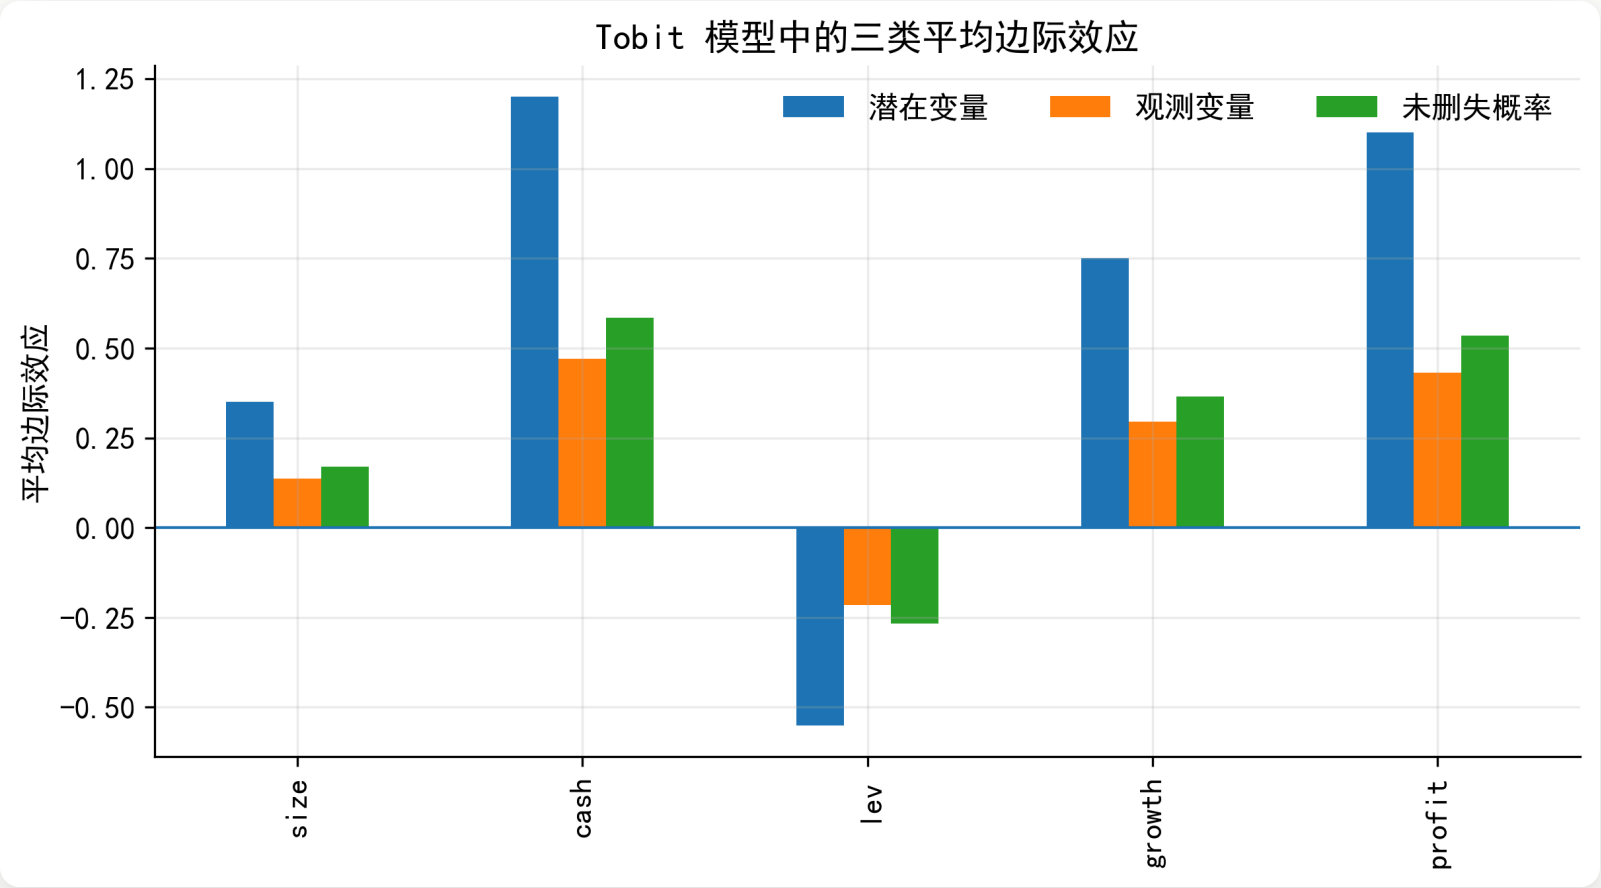
Tobit 模型中的三类平均边际效应
潜在变量
观测变量
未删失概率
平均边际效应
1.25
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
size
cash
lev
growth
profit

案例小结

- OLS 会把边界值当作普通连续值，容易混淆删失机制下的关系
- Tobit 更适合描述潜在投入强度被下限删失的数据生成过程
- `size` 和 `cash` 的影响既可能体现在研发投入概率上，也可能体现在实际投入强度上
- 结果解释应同时报告 Tobit 系数和平均边际效应

附录：手写 MLE 的作用

手写 MLE 不一定是实际应用的首选方式，但有助于理解：

- $y_i = 0$ 的样本提供的是概率信息
- $y_i > 0$ 的样本提供的是连续密度信息
- Tobit 并没有丢掉 0 值样本
- Tobit 也没有把 0 值样本当成普通连续观测

课堂小结

- Tobit 适用于潜在连续变量被删失的情形
- 关键是解释 $y_i = 0$ 或边界值的经济含义
- Tobit 系数首先对应潜变量 y_i^*
- 实证论文通常应重点报告平均边际效应
- 如果 0 是真实选择、样本截断或选择进入，应考虑替代模型

参考文献

- Tobin, J. (1958). Estimation of relationships for limited dependent variables. *Econometrica*, 26(1), 24–36. DOI: 10.2307/1907382.
- Amemiya, T. (1984). Tobit models: A survey. *Journal of Econometrics*, 24(1–2), 3–61. DOI: 10.1016/0304-4076(84)90074-5.
- McDonald, J. F., & Moffitt, R. A. (1980). The uses of Tobit analysis. *The Review of Economics and Statistics*, 62(2), 318–321. DOI: 10.2307/1924766.
- Cragg, J. G. (1971). Some statistical models for limited dependent variables. *Econometrica*, 39(5), 829–844. DOI: 10.2307/1909582.