# Interactive Fixed Effect Models

1. PCA
2. IntFE
3. Applications: SCM, RCM

连玉君 (中山大学)
arlionn@163.com

# Outline

- IntFE 的由来
  - TWFE
  - 变系数模型
  - 共同冲击
- PCA 简介
  - 特征值和特征向量
  - PCA
  - FE, TWFE 和交互固定效应
- IntFE
  - 模型设定
  - 估计方法
- 应用：
  - 回归控制法 (RCM)
  - 合成控制法 (SCM)

# 1. 为何要引入交互固定效应?

- POLS, FE, RE
- 时间趋势和共同冲击
- 变系数模型
- 交互固定效应

# 回顾：POLS, FE, RE

$$Y_{it} = c_0 + \mathbf{x}_{it}'\beta + u_{it}, \quad i = 1, 2, \ldots, N, \;\; t = 1, 2, \ldots, T$$

- POLS: $Y_{it} = c_0 + \mathbf{x}_{it}'\beta + u_{it}$ 假设: $\alpha_i = 0$
- FE: $Y_{it} = c_0 + \alpha_i + \mathbf{x}_{it}'\beta + v_{it}$
- RE: $Y_{it} = c_0 + \mathbf{x}_{it}'\beta + \alpha_i + v_{it}$, 假设: $\text{corr}\left(\alpha_i, v_{it}\right) = 0$
- $\gamma_i = c_0 + \alpha_i$: 不随时间变化的个体特征 (地理位置、性别、种族、基因缺陷等)
- Stata 命令：(预先执行 `xtset id year`)

```
. reg   y x                // POLS

. xtreg y x, re            // RE

. reg   y x i.id           // FE
. xtreg y x, fe            // FE
. reghdfe y x, absorb(id) // FE
```

## 回顾：TFE - Two way Fixed Effects model

- 设定 $u_{it} = \alpha_i + \lambda_t + v_{it}$，即在 FE 的基础上进一步考虑时间维度上的固定效应 $\lambda_t$
- $\lambda_t$: 表示时间维度上宏观冲击，如石油价格变化、货币政策调整等

得到「双向固定效应模型」(TFE)：

$$Y_{it} = c_0 + \alpha_i + \lambda_t + \mathbf{x}_{it}'\beta + v_{it}$$

Stata 命令为：

```
. xtset id year

. xtreg   y x i.year, fe

. reghdfe y x, absorb(id year)
```

# 回顾：解读 TFE

TFE 在文献中通常表述为： $Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \lambda_t + \varepsilon_{it}$

为便于理解，可重新写为： $Y_{it} = \mathbf{x}_{it}'\beta + \sum_{i=1}^{N} \alpha_i A_i + \sum_{t=1}^{T} \lambda_t B_t + \varepsilon_{it}$

- 变量含义：
  - $A_i$ 是个体层面的虚拟变量 (共 $N$ 个)： `i.id`；
    - $\alpha_i$ 是待估参数
  - $B_t$ 则是时间维度上的虚拟变量 (共 $T$ 个)： `i.year`；
    - $\lambda_t$ 是待估参数
- Stata: `reg y x1 x2  i.id  i.year`
- 同质性假设
  - H1：在第 $t$ 年度的宏观冲击 $B_t$ 对所有个体的 $y_{it}$ 的影响具有同质性，均为 $\lambda_t$。
  - H2：第 $i$ 家公司的个体特征 $A_i$ 对该公司所有年度上的 $y_{it}$ 的影响具有同质性，均为 $\alpha_i$。

# 宏观冲击 (共同因素) 的异质性影响

**同质模型：**

$$Y_{it} = \mathbf{x}_{it}'\beta + \sum_{i=1}^{N} \alpha_i A_i + \sum_{t=1}^{T} \lambda_t B_t + \varepsilon_{it}$$

**异质模型：** 假设宏观经济冲击 $B_t$ 会对不同的个体产生不同的影响

$$Y_{it} = \mathbf{x}_{it}'\beta + \sum_{i=1}^{N} \alpha_i A_i + \sum_{i=1}^{N}\sum_{t=1}^{T} \theta_{it} A_i B_t + \varepsilon_{it}$$

或简写为：

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \alpha_i \lambda_t + \varepsilon_{it}$$

```
reg y x  i.id  i.year  i.id#i.year
```

## 宏观冲击 (共同因素) 的异质性影响

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \alpha_i\lambda_t + \varepsilon_{it}$$

- **挑战：** 模型中包含的参数个数超过了样本数 $N \times T$，是无法识别的。
- **应对思路：** 设定一些约束条件，以便减少模型中待估参数的个数 (降维)。
  - 合并。在行业 (地区) 层面上考虑异质性，而不是公司层面上
  - 简化。用时间趋势代替时间虚拟变量
  - 组合。主成分分析 - 将宏观冲击归结为几个主要成分；异质性用因子载荷来反映

# 行业/地区变系数模型

假设：宏观经济冲击的影响仅在比个体更高的层级上（如行业层面）存在异质性。此时，可以把

$$Y_{it} = \mathbf{x}_{it}'\beta + \sum_{i=1}^{N}\alpha_i A_i + \sum_{i=1}^{N}\sum_{t=1}^{T}\theta_{it}A_i B_t + \varepsilon_{it} \quad |or| \quad Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \alpha_i\lambda_t + \varepsilon_{it}$$

改写为：

$$Y_{it} = \mathbf{x}_{it}'\beta + \sum_{i=1}^{N}\alpha_i A_i + \sum_{j=1}^{J}\sum_{t=1}^{T}\theta_{jt}S_j B_t + \varepsilon_{it} \quad |or| \quad Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \gamma_j\lambda_t + \varepsilon_{it}$$

- $S_j$ 表示第 $j$ 个行业对应的虚拟变量，$j = 1, 2, \cdots, J$ 表示行业类别。待估参数：$(p + N + JT)$ 个。
- 为了防止完全共线性，模型中不再包含 $\lambda_t$。当然，也可以保留 $\lambda_t$，但需要删去一个行业虚拟变量。

> Stata 命令：

```
. reg     y x  i.id  i.year  i.industry#i.year
. xtreg   y x        i.year  i.industry#i.year, fe
. reghdfe y x, absorb(id year industry#year)
```

# 时间趋势

## 回顾：i.year 和 c.year 有何区别?

- $y_t = c + \gamma \times t + u_t$
  - `reg y c.year`
- $y_t = c + \sum_{t=1}^{T} \lambda_t B_t + u_t$
  - $y_t = c + \lambda_t + u_t$ (等价简写)
  - `reg y i.year`
- `i.year` 表示 $T$ 个时间虚拟变量
- `c.year` 表示一个连续变量

> 徐婷, 徐云娇, 2020,
> 傻傻分不清：时间趋势项与时间虚拟变量

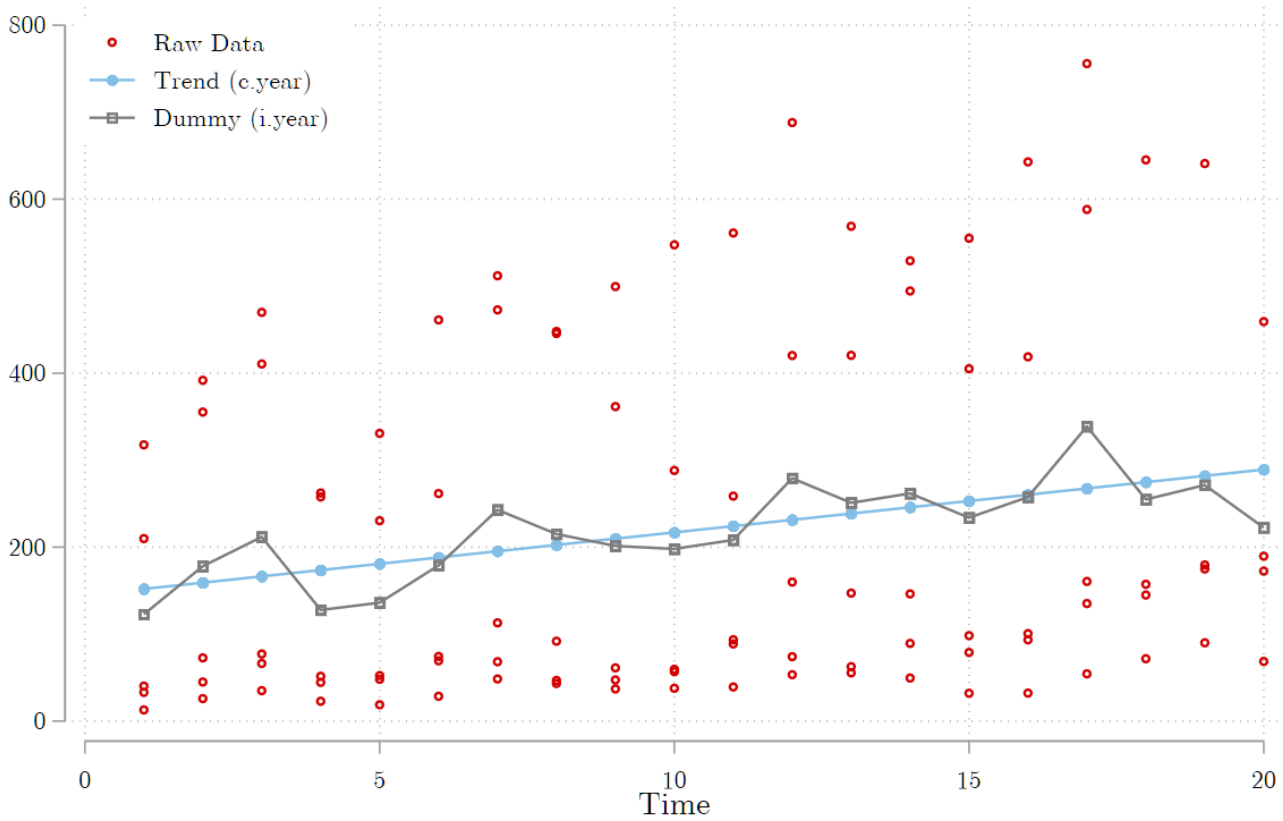

```stata
webuse invest2, clear

rename time year
rename invest y
drop if y >800

reg y c.year    // Trend
predict y_trend

reg y i.year    // Year dummies
predict y_dummy

xtset year company
tw (scatter y year, ms(Oh) msize(*0.5)) ///
   (connect y_trend year)               ///
   (connect y_dummy year),              ///
   legend(order(1 "Raw Data" 2 "Trend (c.year)" 3 "Dummy (i.year)") ///
          ring(0) pos(11))              ///
   scheme(cleanplots)
```

```
. xtset com year
. bysort com: gen Trend = _n
. tab year, gen(yr_dum)
. list com year Trend yr_dum*, sepby(com) noobs

 -----------------   --------   -----------------------------
  company   year      Trend      yr_dum1   yr_dum2   yr_dum3
 -----------------   --------   -----------------------------
        1   2001          1            1         0         0
        1   2002          2            0         1         0
        1   2003          3            0         0         1
 -----------------   --------   -----------------------------
        2   2001          1            1         0         0
        2   2002          2            0         1         0
        2   2003          3            0         0         1
 -----------------   --------   -----------------------------
        3   2001          1            1         0         0
        3   2002          2            0         1         0
        3   2003          3            0         0         1
 -----------------   --------   -----------------------------
```

# 时间趋势项

我们也可以把时间虚拟变量 $\lambda_t$ 替换为时间趋势 $Trend_t = t$。参见 Wooldridge (2010, Sec 11.7, pp. 374-381)

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \lambda_t + \alpha_i t + \varepsilon_{it}$$

- 此时，每个个体都有自己的时间趋势系数 $\theta_i$，表示在样本区间内个体 $i$ 的平均变化趋势。

```
. reg     y x  i.id  i.year  i.id#c.year     // 适合 N 较小，如省级面板
. xtreg   y x        i.year  i.id#c.year, fe // 同上

. reghdfe y x, absorb(id year id#year)       // 推荐，如上市公司数据
```

- 此处，`c.year` 表示把 `year` 变量视为连续变量，用以表示 $Trend_t = t$ 变量。
- **变形：** 假设同一个行业的公司都有相同的时间趋势，则：

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \gamma_j \times t + \varepsilon_{it}$$

```
. reghdfe y x, absorb(id year industry#year)
```

## 时间趋势项：差分处理及解释

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \lambda_t + \alpha_i t + \varepsilon_{it} \qquad (1)$$

我们也可以对 (1) 式进行一阶差分变换，得到：

$$\Delta Y_{it} = \Delta\mathbf{x}_{it}'\beta + \Delta\lambda_t + \alpha_i + \Delta\varepsilon_{it} \qquad (2)$$

注意，$\alpha_i t - \alpha_i(t-1) = \alpha_i$。

(2) 式可以用如下两种方法估计：

```
. xtreg    D.y D.(x1 x2) D.(i.year), fe robust

. xtivreg2 y x1 x2 i.year, fd robust  // fd:=一阶差分
```

## 加入宏观经济变量：模型设定

在很多研究中，我们关心的是一个或多个宏观经济变量 $\mathbf{z}_t$ 对 $Y_{it}$ 的影响。比如，$\mathbf{z}_t$ 可以是人均 GDP ($gdp_t$)，货币增速 ($m_t$)，经济政策不确定性 ($epu_t$) 等。此时，由于 $\mathbf{z}_t$ 与时间虚拟变量 $\lambda_t$ 完全共线性，故删去 $\lambda_t$，模型简写如下：

$$Y_{it} = \alpha_i + \mathbf{x}_{it}'\beta + \mathbf{z}_t'\gamma + u_{it} \tag{1}$$

Stata 命令为：

```
. xtreg   y x z1 z2, fe

. reghdfe y x z1 z2, absorb(id)
```

# 加入宏观经济变量：遗漏变量偏误

> **难点：** 即使我们在 $\mathbf{z}_t$ 中包含了 3-5 个甚至更多的宏观经济变量，仍然可能存在一些被遗漏的变量 (如央行的口头沟通、疫情变化等)，这些变量虽然很重要，但往往难以观测或准确衡量。

假设 $\lambda_t$ 的 DGP 为：$\lambda_t = \mathbf{z}_t'\gamma + \mathbf{w}_t'\eta$，其中 $\mathbf{w}_t$ 不可观测。则，TWFE 可以表示如下：

$$\begin{aligned} Y_{it} &= \mathbf{x}_{it}'\beta + \alpha_i + \lambda_t + \varepsilon_{it} \\ &= \mathbf{x}_{it}'\beta + \alpha_i + (\mathbf{z}_t'\gamma + \mathbf{w}_t'\eta) + \varepsilon_{it} \end{aligned}$$

我们实际估计的模型为：

$$\begin{aligned} Y_{it} &= \alpha_i + \mathbf{x}_{it}'\beta + \mathbf{z}_t'\gamma + u_{it} \\ u_{it} &= \mathbf{w}_t'\eta + \varepsilon_{it} \end{aligned}$$

- **内生性问题：** 如果 $\mathrm{corr}(\mathbf{w}_t, \mathbf{z}_t) \neq 0$ 或 $\mathrm{corr}(\mathbf{w}_t, \mathbf{x}_{it}) \neq 0$，则 $\gamma$ 或 $\beta$ 的 OLS 估计将是有偏的。
- **截面相关问题：** $u_{it} = \mathbf{w}_t'\eta + \varepsilon_{it}$，由于 $\mathbf{w}_t$ 是所有个体面临的共同因素，所以个体间的干扰项存在截面相关，即 $\mathrm{corr}\left(u_{it}, u_{jt}\right) \neq 0 \ (\forall\ i \neq j)$。

# 2. IntFE：面板交互固定效应模型

- IntFE 的基本思想
- Bai (2009) 的模型设定
- IntFE 扩展模型

## IntFE 的基本思想

我们实际估计的模型可能存在遗漏变量偏误，因为 $u_{it} = \mathbf{w}_t'\eta + \varepsilon_{it}$：

$$Y_{it} = \alpha_i + \mathbf{x}_{it}'\beta + \mathbf{z}_t'\gamma + u_{it}$$

> IntFE 模型的设定思想：

虽然 $\mathbf{w}_t'\eta$ 不可观测，但可以将其设定为一组共同因子的组合，即 $F_t'\lambda$ 或 $F_t'\lambda_i$。

在这一架构下，

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + (\mathbf{z}_t'\gamma + \mathbf{w}_t'\eta) + \varepsilon_{it}$$

可以改用如下设定方式 (以避免遗漏变量问题)：

$$Y_{it} = \alpha_i + \mathbf{x}_{it}'\beta + (\mathbf{z}_t'\gamma + F_t'\lambda_i) + \varepsilon_{it}$$

Stata 命令为：

```
. regife y x1 x2 zt1 zt2, absorb(id) ife(id year, 1)
```

## IntFE：Bai (2009) 模型

$$Y_{it} = \mathbf{X}_{it}'\beta + u_{it}, \quad u_{it} = \lambda_i' F_t + \varepsilon_{it} \tag{1}$$

$$\lambda_i' F_t = \lambda_{i1} F_{1t} + \cdots + \lambda_{ir} F_{rt} \tag{2}$$

- 干扰项 $u_{it}$ 具有因子结构，$\lambda_i$ 为因子载荷向量, $F_t$ 是共同因子 (common factors) 向量
- $\lambda_i$, $F_t$, and $\varepsilon_{it}$ 均不可观测。多数应用中, 重点关注的是 $\mathbf{X}_{it}$ 的系数 $\beta$ 。

为便于理解，可以考虑如下模型：

$$Y_{it} = \mathbf{x}_{it}'\beta + \alpha_i + \theta_t + \lambda_i GDP_t + \lambda_i M2_t + \varepsilon_{it} \tag{3}$$

- $GDP_t$ 和 $M2_t$ 分别表示第 $t$ 年的「人均 GDP」增长率和 M2 增速。
- 二者都可以视为「宏观共同因子」(common factor)，只是它们都是**可以观测的**。而在 (2) 式中，共同因子 $F1_t$ 和 $F2_t$ 都是**不可观测的**。

# TWFE, FE, POLS 都是 IntFE 的特例

## TWFE

$$\lambda_i = \begin{bmatrix} \alpha_i \\ 1 \end{bmatrix}, \quad F_t = \begin{bmatrix} 1 \\ \xi_t \end{bmatrix} \quad \Longrightarrow \quad \lambda_i' F_t = \alpha_i + \xi_t$$

- $F_{1t} = 1$ 为常数，对应的因子载荷为 $\lambda_{i1} = \alpha_i$，即个体固定效应；
- $F_{2t} = \xi_t$ 是随时间变化的宏观冲击，假设其对所有公司的影响相同，即因子载荷为 $\lambda_{i2} = 1$

$$Y_{it} = \mathbf{X}_{it}' + \lambda_i' F_t + \varepsilon_{it} \quad \Longrightarrow \quad Y_{it} = \mathbf{X}_{it}' + \alpha_i + \xi_t + \varepsilon_{it}$$

## One-way FE

$$\lambda_i = \begin{bmatrix} \alpha_i \\ 0 \end{bmatrix}, \quad F_t = \begin{bmatrix} 1 \\ \xi_t \end{bmatrix} \quad \Longrightarrow \quad \lambda_i' F_t = \alpha_i$$

$$\lambda_i = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad F_t = \begin{bmatrix} 1 \\ \xi_t \end{bmatrix} \quad \Longrightarrow \quad \lambda_i' F_t = \xi_t$$

## Pooled OLS

$$\lambda_i = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad F_t = \begin{bmatrix} 1 \\ \xi_t \end{bmatrix} \quad \Longrightarrow \quad \lambda_i' F_t = 0$$

## TWFE + IntFE

实证分析中常用的交互固定效应模型设定如下 (参见 Bai, 2009, Eq. (4), p.1233)：

$$Y_{it} = \mathbf{X}_{it}'\beta + \alpha_i + \delta_t + \underbrace{(\lambda_i' F_t + \varepsilon_{it})}_{u_{it}}$$

Stata 命令为：

```
. regife y x1 x2, absorb(id year) ife(id year, 1)
```

## IntFE 扩展模型 (1)

更一般化的设定如下 (参见 Bai, 2009, Eq. (3), p.1230)：

$$Y_{it} = \tau_i + \theta_t + \sum_{k=1}^{r} a_k \lambda_{ik} + \sum_{k=1}^{r} b_k F_{kt} + \sum_{k=1}^{r} c_k \lambda_{ik} F_{kt} + \pi_i' G_t + \eta_{it},$$

其中，$a_k, b_k$ 和 $c_k$ 均为常数或常向量，$G_t$ 是一组不可观测的共同因子。

因此，$X_{it}$ 可以与 $\lambda_i$ 或 $F_t$ 相关，甚至可以与二者都相关。

在给定一些限制性条件后，$\lambda_i$，$F_t$，以及 $\beta$ 都可以被直接估计出来。

## IntFE 扩展模型 (2)

我们可以在复杂度和解释力度之间作出权衡，设定一个更实用的简化的模型 (Pesaran, 2006)：

$$Y_{it} = \underbrace{\alpha_i' \mathbf{d}_t + \mathbf{X}_{it}' \beta}_{\text{可观测}} + \underbrace{\lambda_i' \mathbf{F}_t + \varepsilon_{it}}_{\text{不可观测}}$$

- **可观测部分**：$\mathbf{X}_{it}'$ 和 $\mathbf{d}_t$。其中，$\mathbf{d}_t$ 可以是：
  - $T-1$ 个年度虚拟变量 (假设 $\mathbf{X}$ 中包含常数项)，
  - 或，人均 GDP 增长率 ($gdp_t$)，货币增速 ($m_t$)，经济政策不确定性 ($epu_t$) 等宏观变量。
- **不可观测部分**：$\lambda_i' \mathbf{F}_t + \varepsilon_{it}$，它刻画的是干扰项的特征。

换言之，若把 $(\mathbf{d}_t, \mathbf{F}_t)$ 视为所有宏观经济因素构成的集合，我们把可观测部分 $\mathbf{d}_t$ 作为解释变量来处理，而那些不可观测的则放入复合干扰项 $u_{it} = \lambda_i' \mathbf{F}_t + \varepsilon_{it}$ 中，从而最大限度地克服了遗漏变量偏误。

## IntFE 扩展模型 (3)

$$Y_{it} = \underbrace{\alpha_i' \mathbf{d}_t + \mathbf{X}_{it}' \beta}_{\text{可观测}} + \underbrace{\lambda_i' \mathbf{F}_t + \varepsilon_{it}}_{\text{不可观测}} \tag{1}$$

举个具体的例子。假设我们重点关注 $epu_t$ 的影响，此时模型中无法同时加入 $\lambda_t$ (会导致完全共线性)，但我们又需要控制其它宏观变量的影响 (以免产生遗漏变量偏误)，可以把 (1) 式设定成如下形式：

$$Y_{it} = \alpha_i + \mathbf{X}_{it}' \beta + epu_t \gamma + z_{1t}\theta_1 + z_{2t}\theta_2 + \lambda_i' \mathbf{F}_t + \varepsilon_{it}$$

其中，$z_{1t}, z_{2t}$ 是除了 $epu_t$ 以外的其它可以观测的宏观经济变量，如 人均 GDP 增长率 ($gdp_t$)，货币增速 ($m_t$)，利率水平 ($interest_t$) 等，也可以包括反应某些特定时间段的虚拟变量，如 $crisis = \mathbf{I}(2008 \le t \le 2009)$。

- Note：在模型中放入 $\lambda_t$，即 $T$ 个年度虚拟变量会导致完全共线性，但放入个别年度或某个时间段的虚拟变量则不会导致此问题。

Stata 命令为：

```
. regife y x1 x2 epu m2 gdp, absorb(id) ife(id year, 1)
```

## IntFE 扩展模型 (4)

Bai (2009, eq. (35)-(37)) 还建议了一些更一般化的模型设定方式。

先考虑如下基本模型：

$$Y_{it} = X_{it}'\beta + \mu + \alpha_i + \xi_t + \lambda_i'\mathbf{F}_t + \varepsilon_{it}$$

其中，$\mu$ 是总体均值，$\alpha_i$ 是固定效应，$\xi_t$ 是时间效应，而 $\lambda_i'\mathbf{F}_t$ 是交互效应。为了防止共线性，只需放入 $N-1$ 个个体虚拟变量和 $T-1$ 个时间虚拟变量即可 (参见 Greene (2000, p. 565))，即：

$$\sum_{i=1}^{N}\alpha_i = 0, \quad \sum_{t=1}^{T}\xi_t = 0$$

若进一步加入非时变变量 ($x_i$) 和宏观变量 ($w_t$)，则 (\ref{eq:FEint-Bai-eq26}) 变为：

$$Y_{it} = X_{it}'\varphi + \mu + \alpha_i + \xi_t + x_i'\gamma + w_t'\delta + \lambda_i'\mathbf{F}_t + \varepsilon_{it}$$

还可以做进一步扩展，以便允许非时变变量 ($x_i$) 和宏观变量 ($w_t$) 的影响具有截面异质性：

$$Y_{it} = X_{it}'\phi + \mu + \alpha_i + \xi_t + x_i'\gamma_t + w_t'\delta_i + \lambda_i'\mathbf{F}_t + \varepsilon_{it}$$

# 3. IntFE 估计方法

## 主成分两步法

> 基本思想：采用主成分分析估计共同因子，进而将其作为控制变量加入回归方程 (Coakey et al., 2002)。

对于交互固定效应模型：

$$Y_{it} = \mathbf{X}_{it}'\beta + u_{it}, \quad u_{it} = \lambda_i' F_t + \varepsilon_{it}$$

**第一步**，估计共同因子。假设共同因子与解释变量不相关，即 $E(u_{it}|\mathbf{X}_{it}) = 0$，我们可以先不考虑因子结构，直接对 $Y_{it} = \mathbf{X}_{it}'\beta + u_{it}$ 执行混合 OLS 估计，得到 $\beta$ 的 POLS 估计 $\widehat{\beta}_{OLS}$，以及残差 $\widehat{u}_{it} = Y_{it} - \mathbf{X}_{it}'\widehat{\beta}_{OLS}$，进而对残差进行主成分分析 (PCA)，即估计如下因子模型：

$$\widehat{u}_{it} = \lambda_i' F_t + \varepsilon_{it}$$

由此可获得因子得分最高的 $r$ 个主成分，作为 $F_t$ 的估计值，记为 $\widehat{F}_t$。

**第二步**，估计 $\widehat{\beta}$。用 $\widehat{F}_t$ 做控制变量，对下式执行 OLS 估计，以获得 $\beta$ 的估计值 $\widehat{\beta}$:

$$Y_{it} = \mathbf{X}_{it}'\beta + \lambda_i' \widehat{F}_t + \varepsilon_{it}$$

## 主成分迭代法

- 主成分法的局限
  - Pesaran (2006) 指出，若共同因子与解释变量相关 (这是实际应用中的非常普遍的状况)，采用 Coakey et al. (2002) 的两阶段估计法得到的估计量是不一致的。
- 为此，Bai (2009) 建议采用“主成分迭代法”：对模型施加一些基本的约束条件，以便参数能够识别，进而将 Coakey et al. (2002) 的两步法不断迭代，直到收敛，最终可得一致估计量。
  - 要求：数据为「大 $N$ 大 $T$」结构；
  - 优点：因子与因子载荷都可以是内生的 (即 $\mathbf{F}_t$ 可以与 $\mathbf{X}_{it}$ 相关)。
  - 风险：Bai (2009, pp.1262) 的蒙特卡洛模拟分析表明，当 $N$ 较小时，IntFE 估计量是不一致的。这意味着，在省级面板中要谨慎使用该模型。
- 扩展阅读
  - 有关因子模型和主成分分析的相关介绍参见 Bai and Wang (2016) 以及 Fan et al. (2021, Section 3)。
  - 非平行面板情形下的估计方法参见 Czarnowske and Stammann (2020)。

> (补充说明)

# PCA：主成分分析

- [MV] pca
  - 姚和平, 2022, Stata：特征值、特征向量与主成分分析-pca, 连享会 No.886.
  - 周翔宇, 2022, 主成分分析-交互固定效应基础：协方差矩阵的几何意义, 连享会 No.845.
  - 左祥太, 2021, Stata可视化：biplot一图看尽方差、相关性和主成分, 连享会 No.814.
  - 梁淑珍, 2022, 论文复现：顶刊JF中的因子分析-谁更容易当CEO？, 连享会 No.993.
  - 王晓娟, 甘徐沁, 2021, regife：面板交互固定效应模型-Interactive Fixed Effect, 连享会 No.42.
  - 郑宇, 2021, Stata：平行趋势不满足？主成分DID来帮你！- pcdid, 连享会 No.760.

# 协方差矩阵

> Source: A geometric interpretation of the covariance matrix,
>
> -中文版-

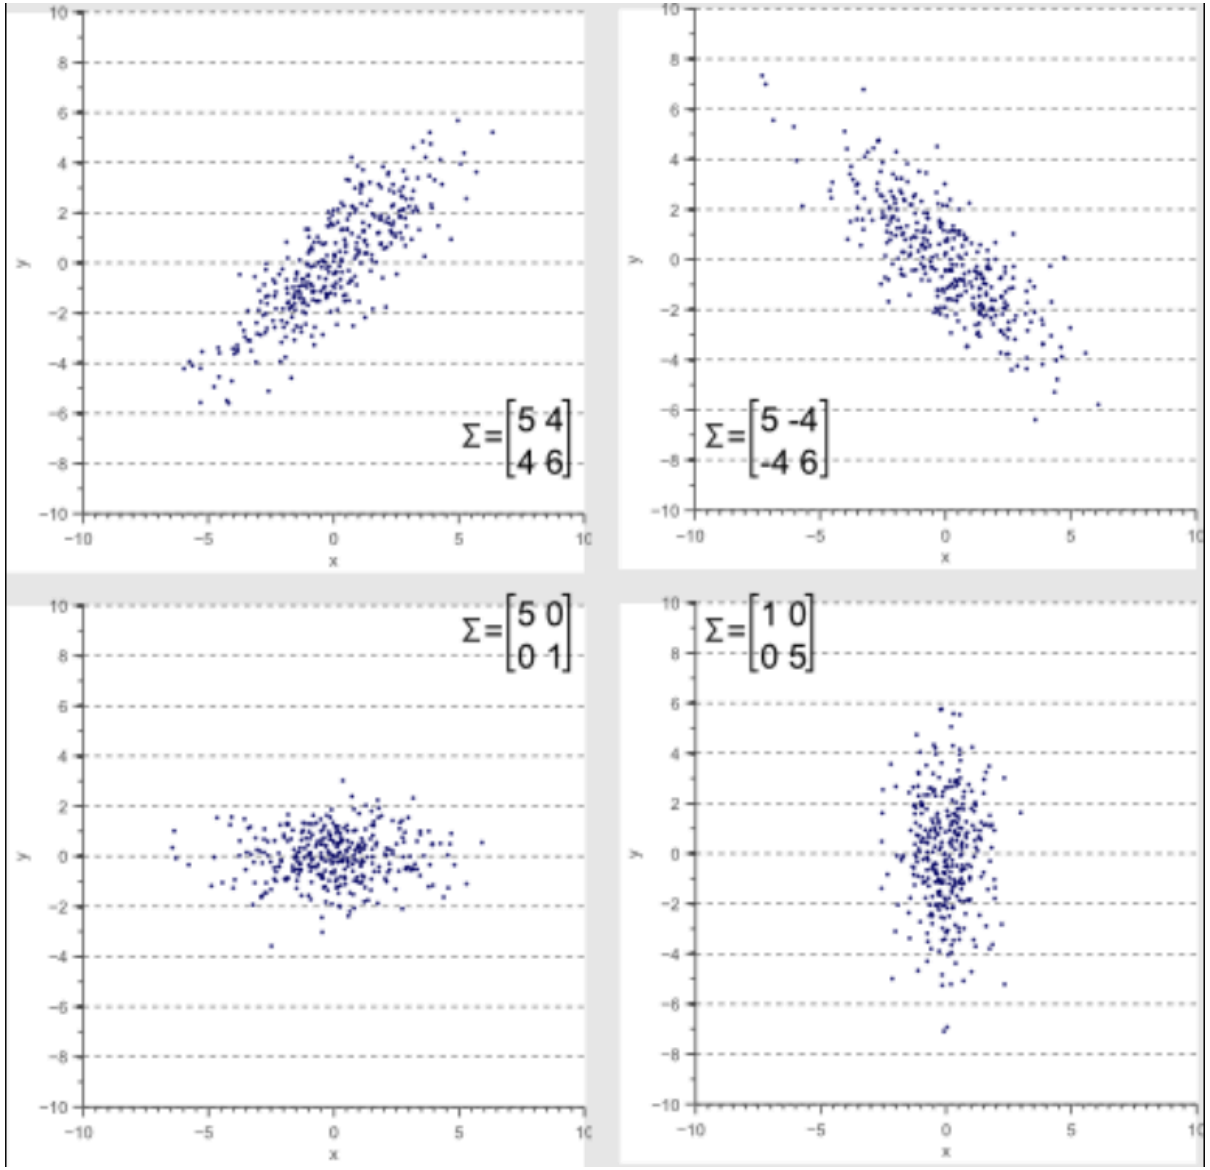

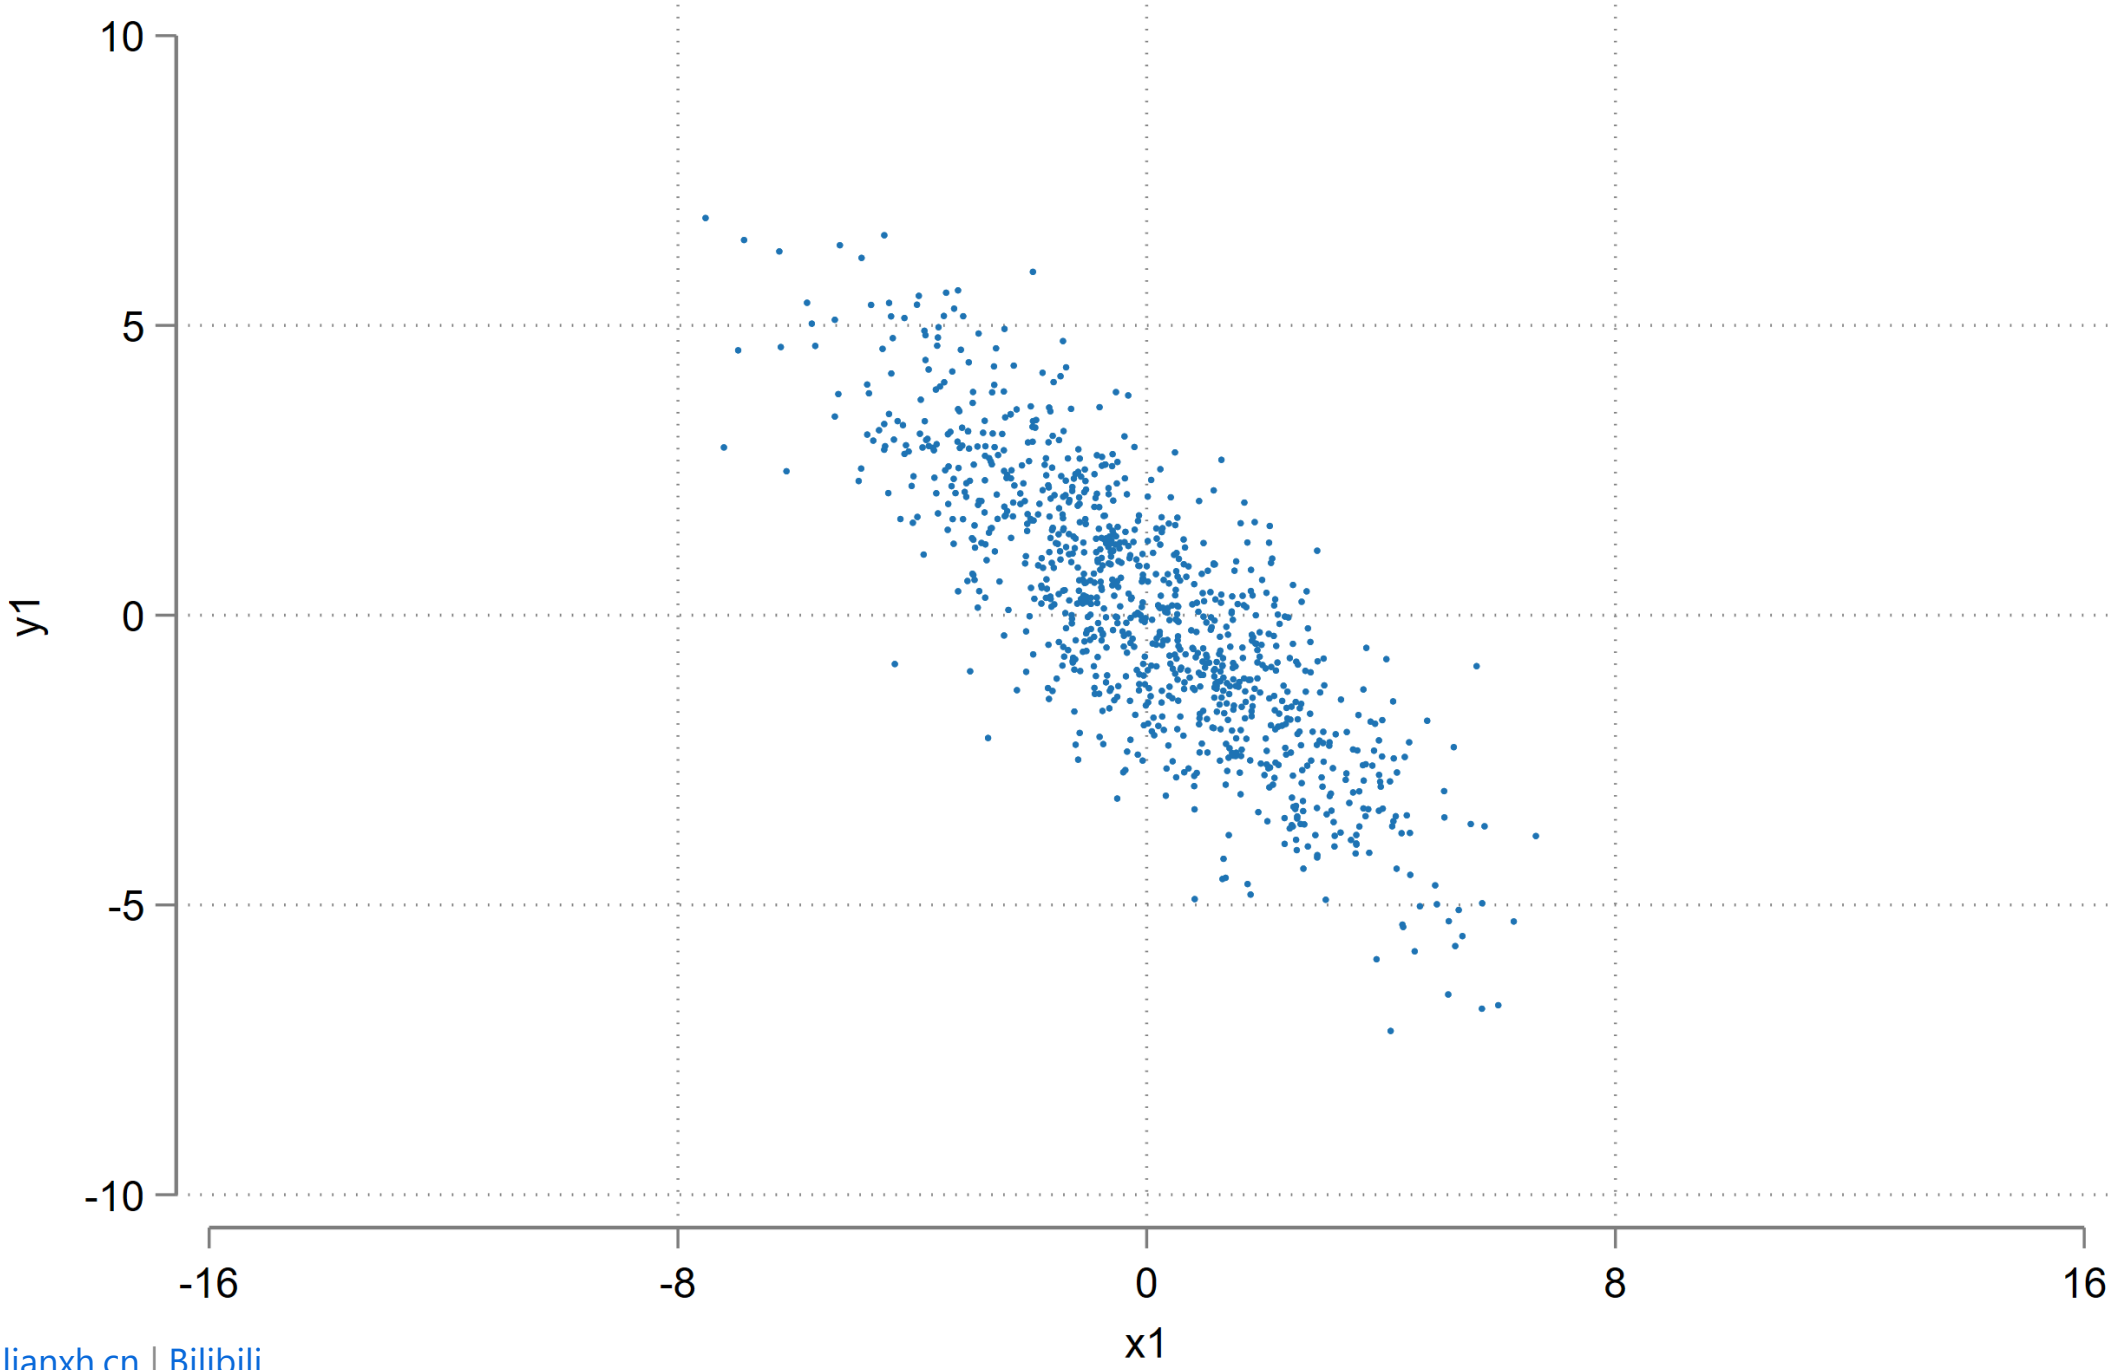
10
5
0
-5
-10
y1
-16
-8
0
8
16
x1

# 特征向量和特征值

给定如下 **方差-协方差矩阵**：

$$\Sigma = \begin{bmatrix} 5, -4 \\ -4, 5 \end{bmatrix}$$

- **第一特征向量**：指向数据“最大方差”的方向，它的模为 **最大特征值** (向量的长度)
- **第二大特征向量**：指向数据“第二大方差”的方向，且与第一大特征向量正交(垂直)。

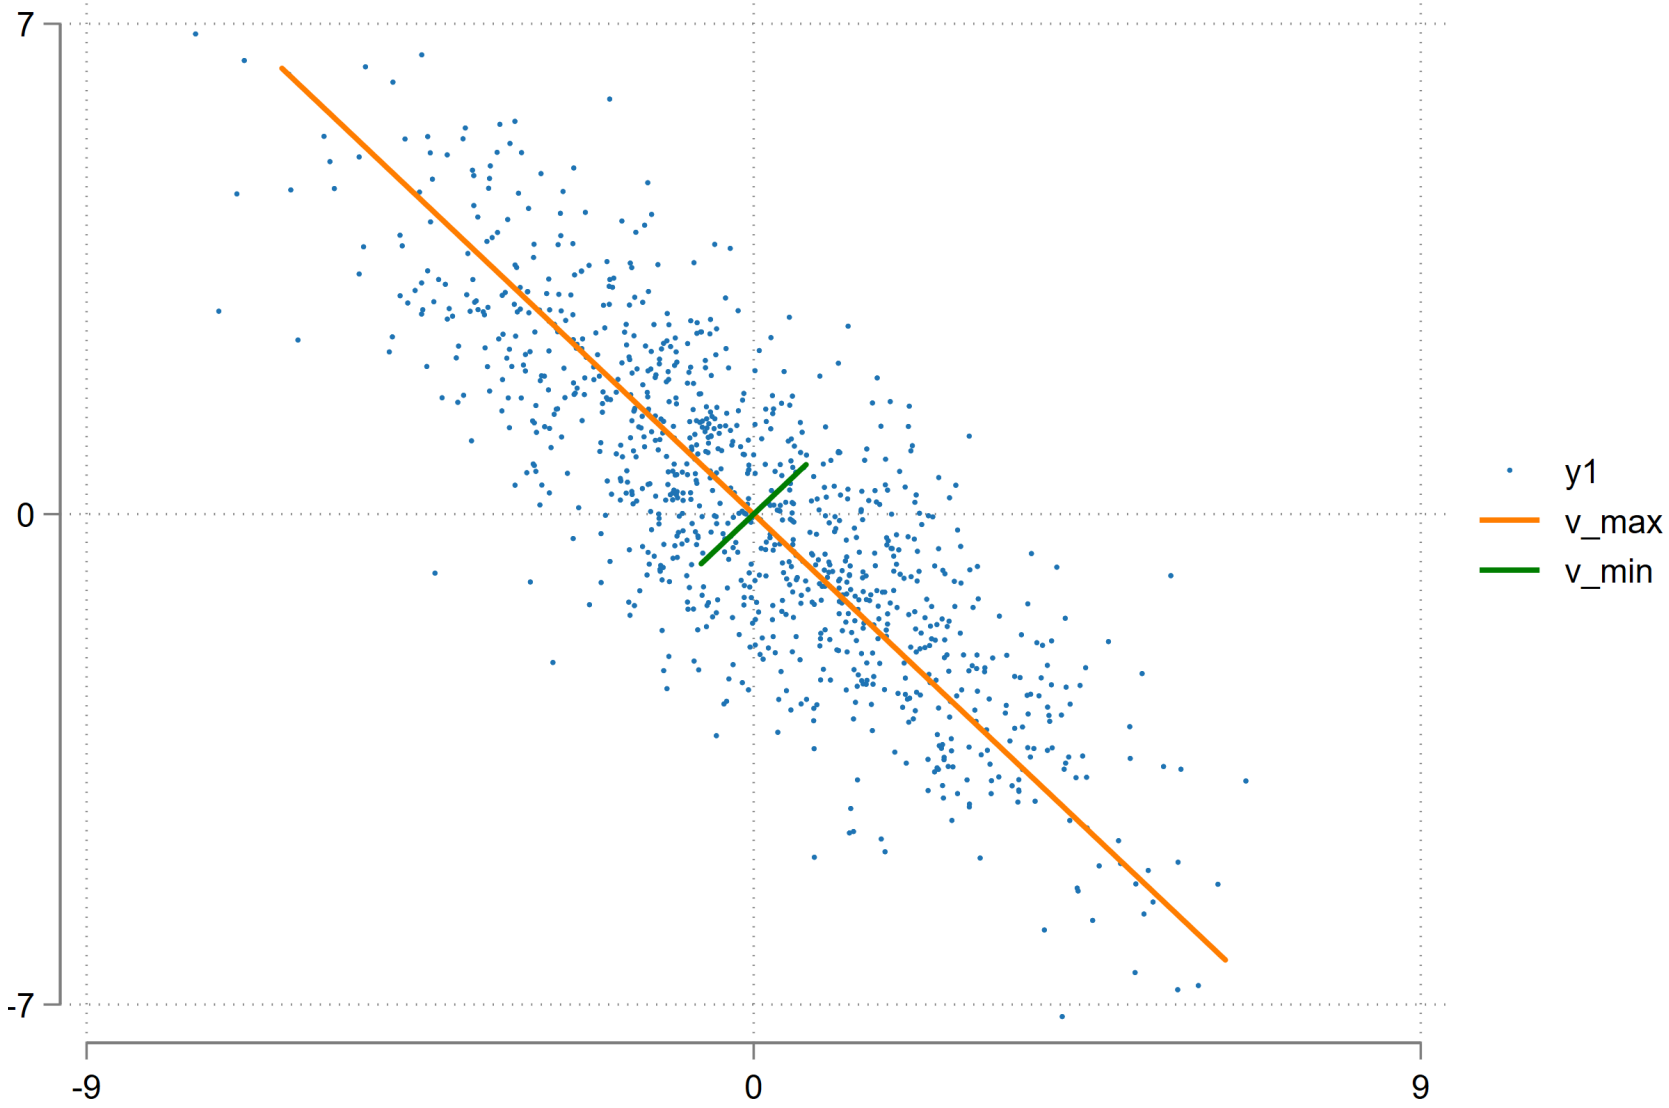

上图中数据集的协方差矩阵为:

$$\Sigma = \begin{bmatrix} 5, -4 \\ -4, 5 \end{bmatrix}$$

## 特征向量和特征值

$$\Sigma v = \lambda v \quad \Longrightarrow \quad (\Sigma - \lambda I)v = 0$$

$$\begin{bmatrix} 5-\lambda, & -4 \\ -4, & 5-\lambda \end{bmatrix} v = 0$$

对应的最大、最小特征向量分别为:

$$v_1 = \begin{bmatrix} -\frac{\sqrt{2}}{2} \\ +\frac{\sqrt{2}}{2} \end{bmatrix}, \lambda_1 = 9 \qquad v_2 = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix}, \lambda_2 = 1$$

在图中标出两个模为对应特征值的特征向量，可以直观地感受到“指向最大方差方向”和“指向最小方差方向”的含义。

## 特征值和特征向量 refs

- 最清楚的一个解释：A geometric interpretation of the covariance matrix, 中文译文
- Feature extraction using PCA
- Powell, V., L. Lehe, Principal Component Analysis，给出了非常清楚的介绍
- 花了10分钟，终于弄懂了特征值和特征向量到底有什么意义，在上一篇基础上进行了更为生动的动画演示

# PCA 的降维效果图示

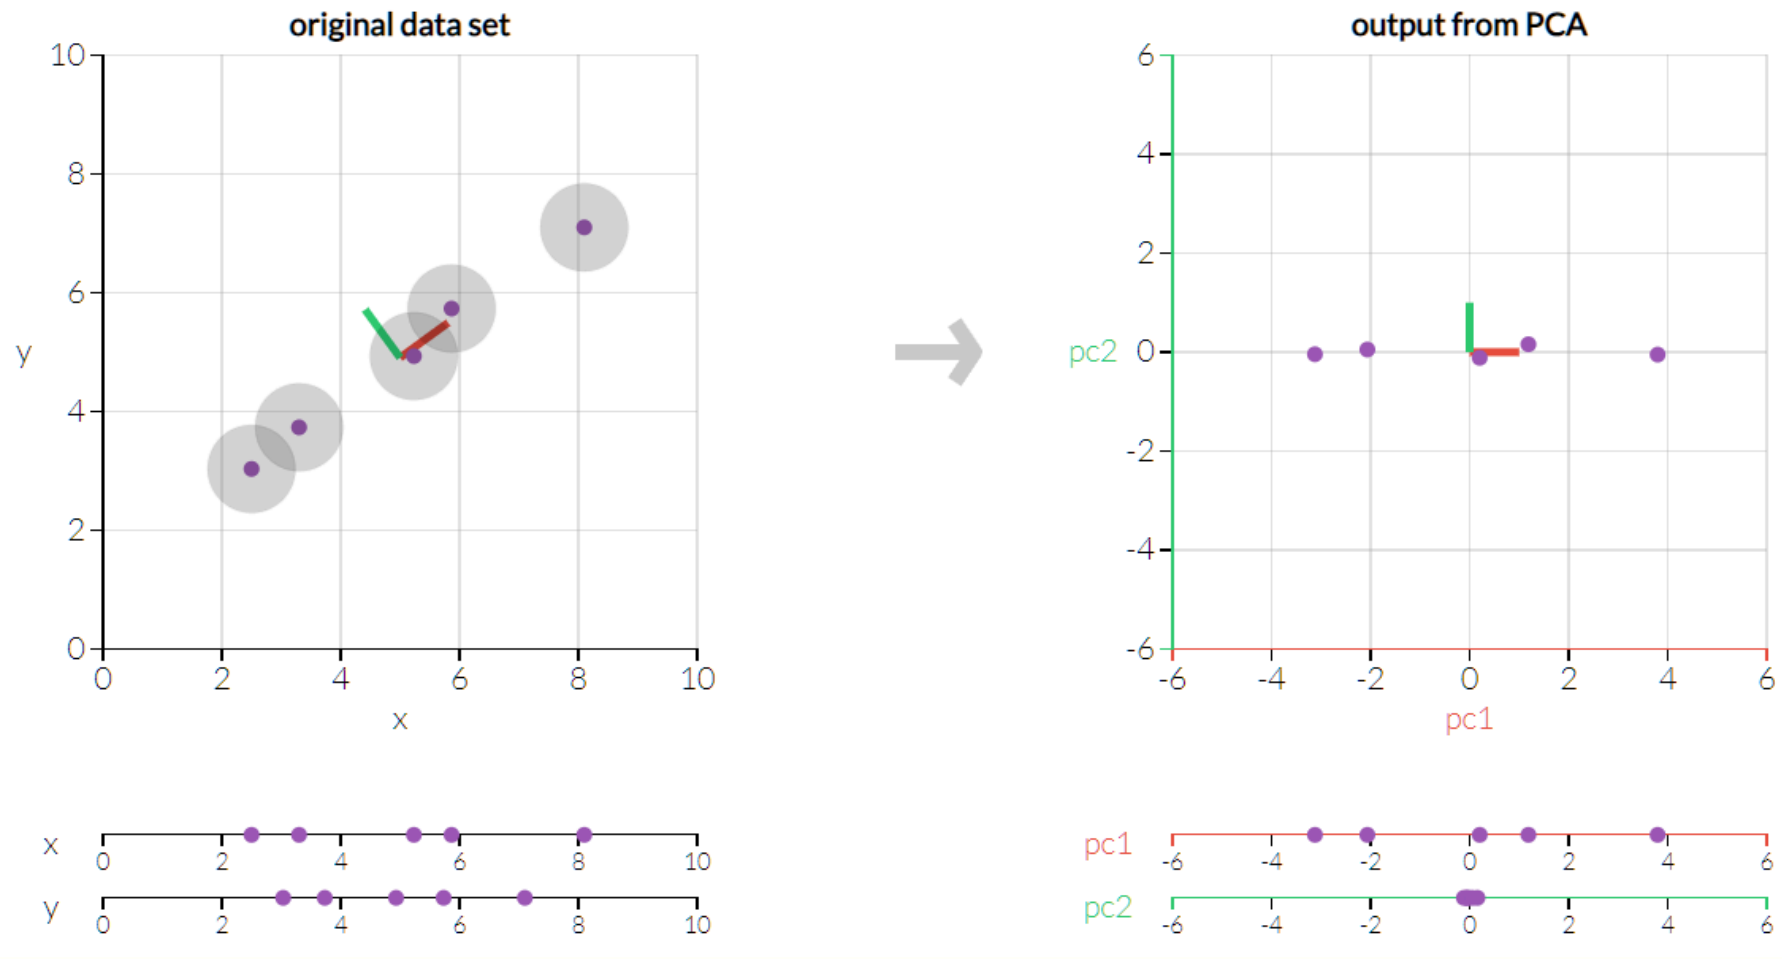


Source: Powell, V., L. Lehe, Principal Component Analysis

# 三维数据 (3 个变量)

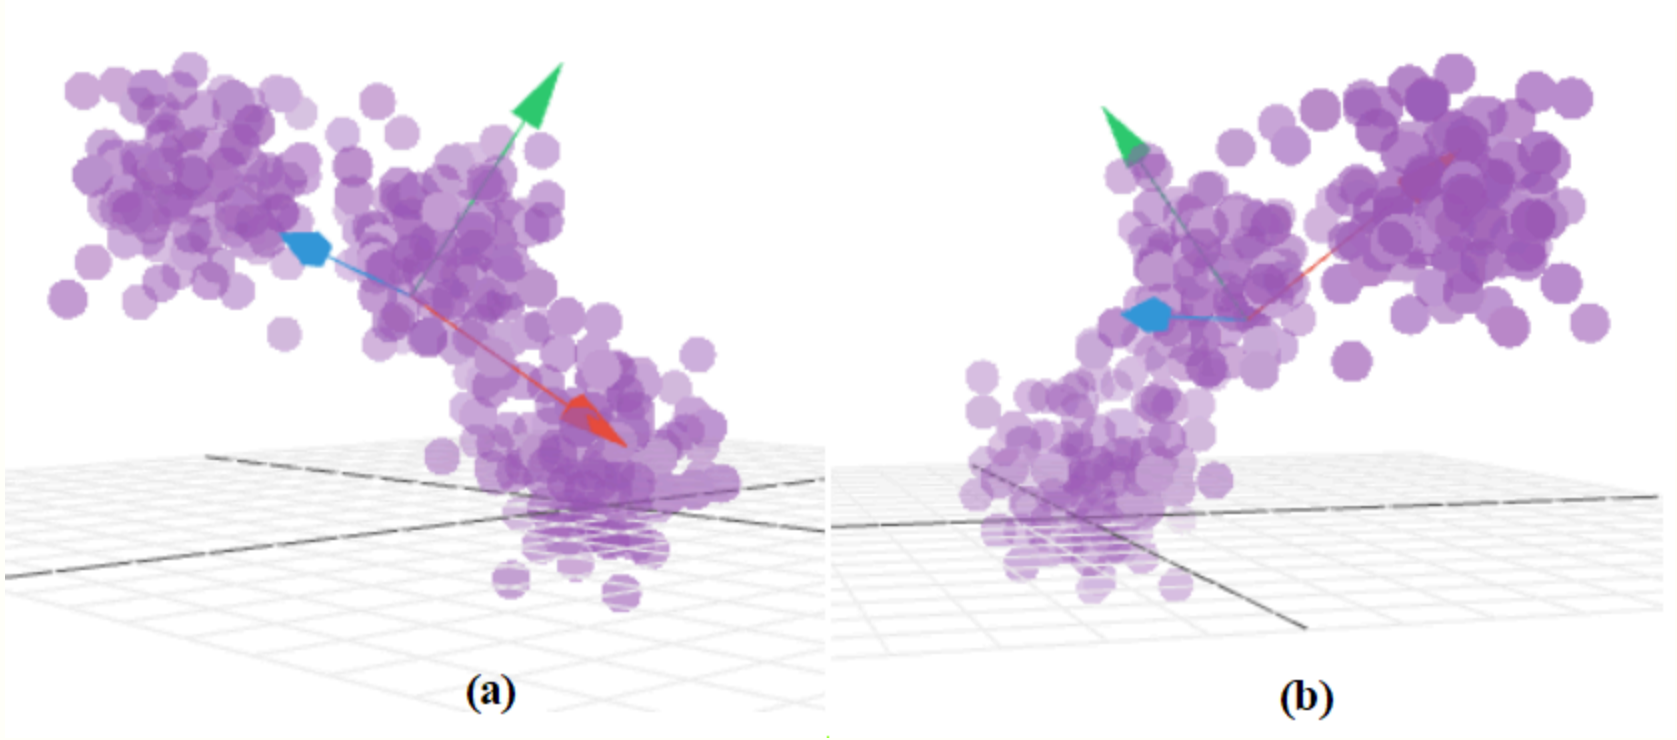


> Source: Powell, V., L. Lehe, Principal Component Analysis
>
> 点击查看动图

# Stata 实例

```
  . sysuse auto, clear
  . pca mpg headroom wei len turn, components(3)

Principal components/correlation            Number of obs    =   74
                                            Number of comp.  =    3
                                            Trace            =    5
  Rotation: (unrotated = principal)         Rho              = 0.9595

  --------------------------------------------------------------------------
     Component |   Eigenvalue   Difference         Proportion   Cumulative
  -------------+------------------------------------------------------------
         Comp1 |      3.80232       3.1003             0.7605       0.7605
         Comp2 |      .702013      .408749             0.1404       0.9009
         Comp3 |      .293264      .143647             0.0587       0.9595
         Comp4 |      .149617     .0968272             0.0299       0.9894
         Comp5 |     .0527895            .             0.0106       1.0000
  --------------------------------------------------------------------------
```

- Comp1 的特征值为 3.80232，占总方差的 76.05%。
- Comp2 的特征值为 0.702013，占总方差的 14.04%，累积解释比例为 90.09%。
- Comp3 的特征值为 0.293264，占总方差的 5.87%，累积解释比例为 95.95%。
- 前三个成分 累积解释了约 95.95% 的总方差，表明前三个主成分保留了大部分数据的原始信息。

(continue……)

```
Principal components (eigenvectors)

    ----------------------------------------------------------
        Variable |    Comp1     Comp2     Comp3 | Unexplained
    -------------+------------------------------+-------------
             mpg |  -0.4474    0.1909    0.8305 |      .01095
        headroom |   0.3124    0.9457   -0.0244 |     .001014
          weight |   0.4918   -0.1436    0.1143 |      .06192
          length |   0.4941   -0.0944    0.1653 |      .05762
            turn |   0.4650   -0.1995    0.5190 |       .0709
    ----------------------------------------------------------
```

- Comp1 的主要负载在变量 length, weight, turn 和 headroom 上，表示第一主成分主要反映了车辆的整体特征。
- Comp2 主要负载在变量 headroom 上，表明第二主成分与「**头部空间**」的变化有很大关系。
- Comp3 主要负载在变量 mpg 上，表明第三主成分主要反映了「**油耗**」的变化。

# PCA 图示

> [MV] biplot　　-推文-

```
sysuse "auto.dta", clear

biplot mpg headroom wei len turn
```

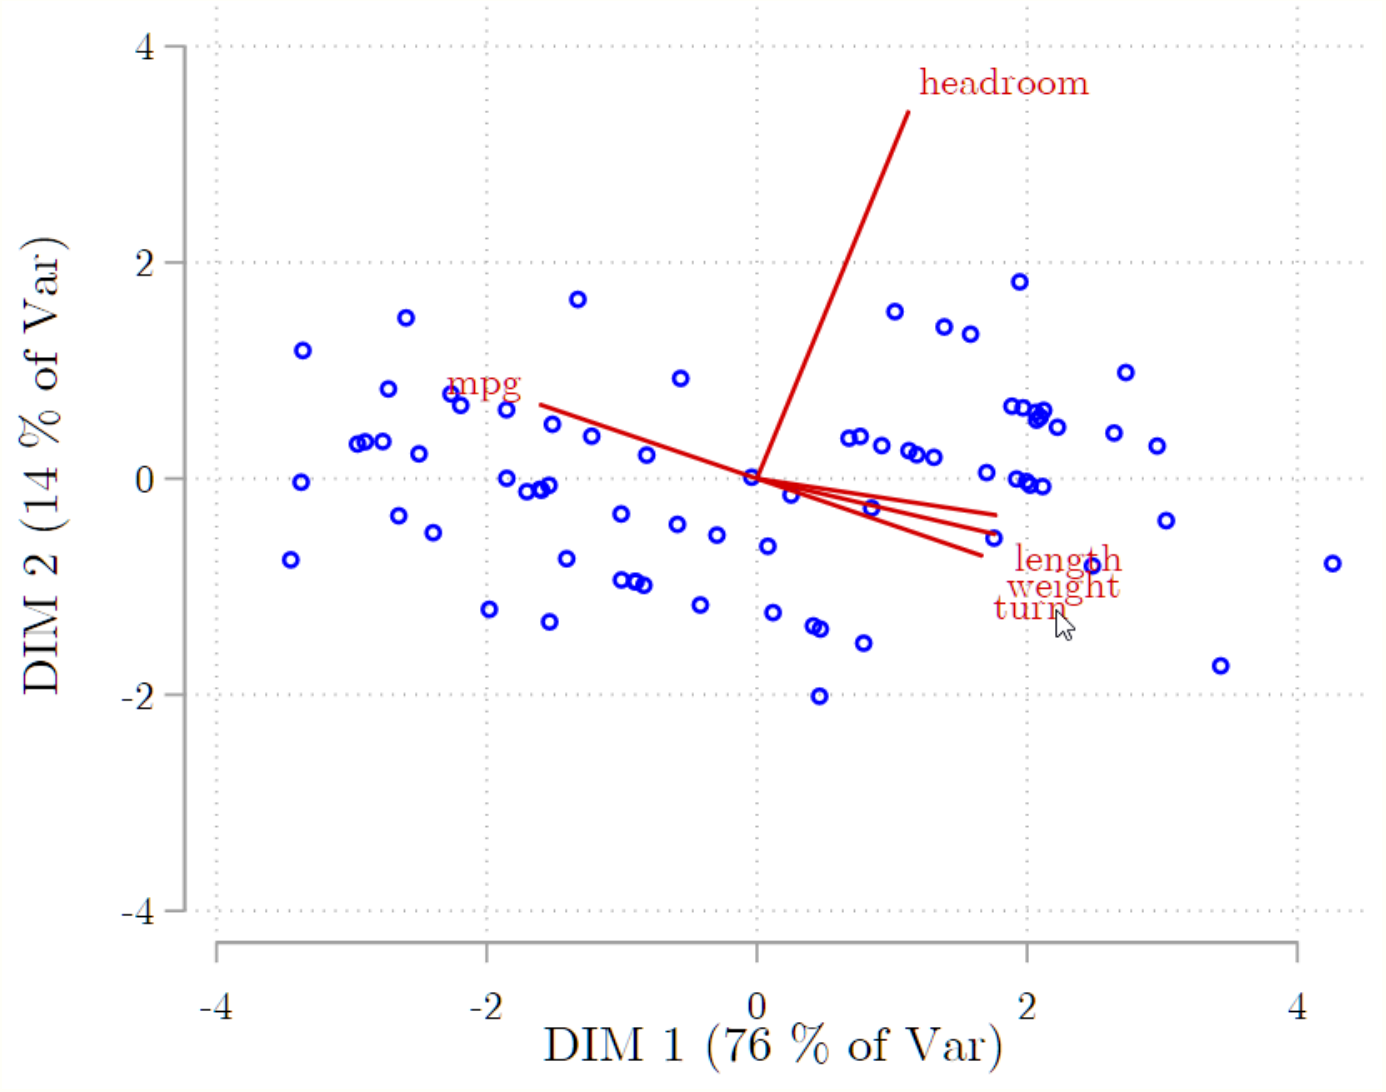

# IntFE 的应用

- 因果推断：用 IntFE 模型预测/估算「反事实」
  - 回归控制法（`help rcm`）
  - Lasso-合成控制法（`help lasso`）
- 缓解遗漏变量偏误

# xtivdfreg: IV with IFE

> Kripfganz, S., & Sarafidis, V. (2021). Instrumental-variable estimation of large-T panel-data models with common factors. **The Stata Journal**, 21(3), 659–686. Link, PDF, Google. -cited-

- Abstract. In this article, we introduce the xtivdfreg command, which implements a general instrumental-variables (IV) approach for fitting panel-data models with many time-series observations, $T$, and unobserved common factors or interactive effects, as developed by Norkute et al. (2021, Journal of Econometrics 220: 416-446) and Cui et al. (2020a, ISER Discussion Paper 1101). The underlying idea of this approach is to project out the common factors from exogenous covariates using principal-components analysis and to run IV regression in both of two stages, using defactored covariates as instruments. The resulting two-stage IV estimator is valid for models with homogeneous or heterogeneous slope coefficients and has several advantages relative to existing popular approaches.

In addition, the xtivdfreg command extends the two-stage IV approach in two major ways. First, the algorithm accommodates estimation of unbalanced panels. Second, the algorithm permits a flexible specification of instruments.

- Norkutė, M., Sarafidis, V., Yamagata, T., & Cui, G. (2021). Instrumental variable estimation of dynamic linear panel data models with defactored regressors and a multifactor error structure. **Journal of Econometrics**, 220(2), 416–446. Link, PDF, Google.
- Cui, G., Norkutė, M., Sarafidis, V., & Yamagata, T. (2021). Two-stage instrumental variable estimation of linear panel data models with interactive effects. **The Econometrics Journal**, 25(2), 340–361. Link, PDF, Google. -Replication-

# IV-IFE：工具变量估计法

- Norkutė, M., Sarafidis, V., Yamagata, T., & Cui, G. (2021). Instrumental variable estimation of dynamic linear panel data models with defactored regressors and a multifactor error structure. **Journal of Econometrics**, 220(2), 416–446. Link, PDF, Google.
- Cui, G., Norkutė, M., Sarafidis, V., & Yamagata, T. (2021). Two-stage instrumental variable estimation of linear panel data models with interactive effects. **The Econometrics Journal**, 25(2), 340–361. Link, PDF, Google. -Replication-
- Kripfganz, S., & Sarafidis, V. (2021). Instrumental-variable estimation of large-T panel-data models with common factors. **The Stata Journal**, 21(3), 659–686. Link, PDF, Google. -cited-, Slides， `xtivdfreg`
- Kripfganz, S., and V. Sarafidis (2024). Estimating spatial dynamic panel data models with unobserved common factors in Stata. Journal of Statistical Software, forthcoming. -PDF-. 空间分布滞后 IntFE 模型 `spxtivdfreg`

1. Bai, J. (2009). Panel Data Models with Interactive Fixed Effects. *Econometrica*, 77(4), 1229–1279. Link, PDF, Google. `regife`
2. Correia, S. (2016). Estimating Multi-Way Fixed Effect Models with reghdfe. *Proceedings of the 2016 Stata Conference: Chicago*. Link, PDF, Google. `reghdfe`
3. Ditzen, J. (2018). Estimating Dynamic Common-Correlated Effects in Stata. *Stata Journal*, 18(3), 585–617. Link, PDF, Google. `xtcce` , `xtcce2`
4. Gomez, M. (2015). Stata Module to Estimate Linear Models with Interactive Fixed Effects. *Statistical Software Components*: S458042. Link, Google. `regife`
5. Norkuté, M., Sarafidis, V., Yamagata, T., & Cui, G. (2021). Instrumental Variable Estimation of Dynamic Linear Panel Data Models with Defactored Regressors and a Multifactor Error Structure. *Journal of Econometrics*, 220(2), 416–446. Link, PDF, Google. `xtivdfreg`
6. Pesaran, M. H. (2006). Estimation and Inference in Large Heterogeneous Panels with a Multifactor Error Structure. *Econometrica*, 74(4), 967–1010. Link, PDF, Google. `xtmg`

# 动态空间 IntFE

> Kripfganz, S., and V. Sarafidis (2024). Estimating spatial dynamic panel data models with unobserved common factors in Stata. Journal of Statistical Software, forthcoming. -PDF-. `spxtivdfreg`

```
ssc install xtivdfreg, all replace

// or 从作者主页安装
net install xtivdfreg, from(http://www.kripfganz.de/stata/)
```

# 动态空间 IntFE：同质空间模型

我们考虑如下包含 $N$ 个截面单元和 $T$ 个时间周期的空间面板数据模型：

$$y_{it} = \psi \sum_{j=1}^{N} w_{ij} y_{jt} + \rho y_{it-1} + \mathbf{x}_{it}^{\top} \boldsymbol{\beta} + \gamma_{y,i}^{\top} \mathbf{f}_{y,t} + \varepsilon_{it},$$

- $y_{it-1}$：捕捉状态依赖的动态或时间效应。
- 复合干扰项：$\mathbf{f}_{y,t}$ 和 $\boldsymbol{\gamma}_{y,i}$ 分别表示 $r_y \times 1$ 的潜在因子和因子载荷向量，而 $\varepsilon_{it}$ 是个体特有的误差项
- $y_{it-1}$ 相对于共同因子 $\mathbf{f}_{y,t}$ 是内生的。
- “空间滞后”变量 $\sum_{j=1}^{N} w_{ij} y_{jt}$ 是个体 $i$ 的「邻居」的结果变量的加权平均值。
  - $w_{ij}$ 表示 $N \times N$ 空间权重矩阵 $\mathbf{W}_N$ 的第 $(i, j)$ 个元素。$wij$ 与单元 $i$ 和 $j$ 之间的距离成反比。假设 $\mathbf{W}N$ 是已知的。
  - 空间滞后变量 $\sum_{j=1}^{N} w_{ij} y_{jt}$ 本质上是内生的，因为它是在空间交互过程中产生的：一个代理人的 $yit$ 值与其邻近代理人的 $y_{it}$ 值同时确定 (Elhorst 2014b)。
    - 这种代理人之间的空间关联可能归因于同伴效应、溢出效应或传染效应，以及战略互动等。

## 动态空间 IntFE：扩展模型

`spxtivdfreg` 包也允许加入时空滞后、协变量的空间滞后或进一步的自回归项。扩展如下：

$$y_{it} = \sum_{\tau=0}^{S} \psi_\tau \sum_{j=1}^{N} w_{ij} y_{jt-\tau} + \sum_{\tau=1}^{S} \rho_\tau y_{it-\tau} + \mathbf{x}_{it}^\top \beta + \sum_{j=1}^{N} w_{ij} \mathbf{x}_{jt}^\top \delta + \gamma_{y,i}^\top \mathbf{f}_{y,t} + \varepsilon_{it},$$
$$i = 1, 2, \ldots, N, \quad t = 2 - S, \ldots, T.$$

- 该模型可以看作是具有广义自回归结构的动态空间 Durbin 模型。
- 特殊情况 $\rho_\tau = 0$ 对于 $\tau > 1$，详见 Elhorst (2012)。
- $\sum_{j=1}^{N} w_{ij} \mathbf{x}_{jt}$ 表示存在“外生网络效应”或“上下文效应”，详见 Manski (1993)。